

Математическая статистика

7 июня 2014 г.

Глава 1

ОСНОВЫ

1.1 Методы оценок характеристик наблюдаемых случайных величин

x_1, \dots, x_n — независимые одинаково распределённые случайные величины с неизвестной функцией распределения F . Логично, что вероятность выпадения каждого x_k (вероятность того, что наугад взятый из выборки x будет равен x_k) одинакова

$$P(x = x_k) = \frac{1}{n}$$

Цель — найти F или сказать что-то о её свойствах.

1.1.1 Эмпирическая функция распределения

Определение 1.1.1: Эмпирическая функция распределения

Эмпирической (выборочной) функцией распределения, построенной по выборке x_1, \dots, x_n , называется функция

$$F_n(x) = \frac{1}{n} \cdot \sum_{k=1}^n \mathbb{1}(x_k \leq x)$$

Теорема 1.1.2

Неизвестная функция распределения $F(x)$ может быть сколь угодно точно восстановлена по выборке достаточно большого объёма [1, стр. 25].

$$\mathbb{P}\left(F_n(x) \xrightarrow[n \rightarrow \infty]{} F(x)\right) = 1$$

Идея доказательства. Вспомним, чему равна эмпирическая функция рас-

пределения

$$F_n(x) = \frac{1}{n} \cdot \sum_{k=1}^n \mathbb{1}(x_k \leq x)$$

Заметим, что индикаторы $\mathbb{1}(x_k \leq x)$ являются независимыми одинаково распределёнными случайными величинами, а функцию распределения $F(x)$ можно записать следующим образом

$$F(x) = \mathbb{P}\{x_1 \leq x\} = M\mathbb{1}(x_1 \leq x)$$

Так как эмпирическая функция распределения является средним арифметическим индикаторов, то по усиленному закону больших чисел она сходится к неизвестной функции распределения почти наверное при устремлении длины выборки к бесконечности

$$F_n(x) = \frac{1}{n} \cdot \sum_{k=1}^n \mathbb{1}(x_k \leq x) \xrightarrow[n \rightarrow \infty]{a.s.} M\mathbb{1}(x_1 \leq x) = F(x)$$

Теорема доказана

$$F_n(x) \xrightarrow[n \rightarrow \infty]{a.s.} F(x)$$

□

1.1.2 Гистограмма

Как можно попытаться отследить плотность распределения? Постараемся найти функцию распределения, а потом и плотность.

Допустим, F имеет хорошую (непрерывную) плотность. Как тогда из F получить p ?

Мы знаем, что $F' = p$, но это никому не нужно, так как F'_n — производная ступенчатой функции, которая почти везде будет равна нулю.

Но также мы помним, что

$$F(b) - F(a) = \int_a^b p(x) dx$$

Положим $a = x$ и введём $\Delta_x = b - x$

$$F(x + \Delta_x) - F(x) = \int_x^{x+\Delta_x} p(y) dy$$

Делим обе части на Δ_x .

$$\frac{1}{\Delta_x} \cdot \int_x^{x+\Delta_x} p(y) dy = \frac{F(x + \Delta_x) - F(x)}{\Delta_x}$$

Несложно заметить, что при достаточно малых значениях Δ_x получаем плотность распределения $p(x)$

$$\frac{\Delta F(x)}{\Delta_x} \xrightarrow{\Delta_x \rightarrow 0} \frac{dF(x)}{dx} = p(x)$$

Значит, можем заменить $p(x)$ не производной, а такой разностью.

$$p(x) \approx \frac{F(x + \Delta) - F(x)}{\Delta}$$

Возьмём m полуинтервалов на числовой прямой $I_j = (a_{j-1}, a_j], i = \overline{1, m}$ таких, что все значения выборки попадают в один из них. Для этого определим пару свойств точек, ограничивающих эти интервалы:

1. Каждая следующая точка строго правее (больше) предыдущей. (так как зачем нам одинаковые точки?)

$$a_0 < a_1 < \dots < a_m$$

2. Каждое значение выборки должно попадать ровно в один полуинтервал. Очевидно, что данные полуинтервалы I_j не пересекаются между собой. Значит, осталось потребовать, чтобы крайнее левое значение было меньше минимального значения из выборки, а крайнее правое — не меньше максимального

$$a_0 < \min(X) \leq \max(X) \leq a_m$$

Введём функцию $q(y)$

$$q(y) = \sum_{j=1}^m \frac{F(a_j) - F(a_{j-1})}{a_j - a_{j-1}} \cdot \mathbb{1}(y \in I_j)$$

Определим последовательность функций $q_n(y)$, заменив $F(x)$ на $F_n(x)$ в предыдущем определении

$$q_n(y) = \sum_{j=1}^m \frac{F_n(a_j) - F_n(a_{j-1})}{a_j - a_{j-1}} \cdot \mathbb{1}(y \in I_j) \quad (1.1)$$

Отметим, что q_n сходится к q почти наверное (согласно закону больших чисел), а q в свою очередь сходится к p (согласно центральной предельной теореме)

$$q_n(y) \xrightarrow[n \rightarrow \infty]{a.s.} q(y) \xrightarrow[m \rightarrow \infty]{} p(y)$$

Функция q_n называется **гистограммой**.

Избавимся от a_j в формуле, а для этого вспомним, чему равно $F_n(x)$

$$F_n(x) = \frac{1}{n} \cdot \sum_{k=1}^n \mathbb{1}(x_k \leq x)$$

Теперь посмотрим, чему равна разность $F_n(a_j) - F_n(a_{j-1})$, которая, как мы видим, является вероятностью того, что x попало в отрезок I_j

$$\begin{aligned} & F_n(a_j) - F_n(a_{j-1}) = \\ &= \frac{1}{n} \cdot \sum_{k=1}^n \mathbb{1}(x_k \leq a_j) - \frac{1}{n} \cdot \sum_{k=1}^n \mathbb{1}(x_k \leq a_{j-1}) \end{aligned}$$

Сгруппируем слагаемые и получим чуть более компактную запись разности

$$\begin{aligned} F_n(a_j) - F_n(a_{j-1}) &= \\ &= \frac{1}{n} \cdot \sum_{k=1}^n [\mathbb{1}(x_k \leq a_j) - \mathbb{1}(x_k \leq a_{j-1})] \end{aligned} \quad (1.2)$$

Рассмотрим возможные значения индикаторов

Если оба индикатора равны единице, это значит, что x_k не больше a_j и не больше a_{j-1} . Поскольку $a_{j-1} \leq a_j$, то можно обойтись тем, что $x \leq a_{j-1}$

$$\begin{aligned} \begin{cases} \mathbb{1}(x_k \leq a_j) = 1 \\ \mathbb{1}(x_k \leq a_{j-1}) = 1 \\ a_{j-1} \leq a_j \end{cases} &\Rightarrow \begin{cases} x_k \leq a_j \\ x_k \leq a_{j-1} \\ a_{j-1} \leq a_j \end{cases} \\ &\Rightarrow x_k \leq a_{j-1} \leq a_j \Rightarrow x_k \leq a_{j-1} \end{aligned}$$

Такая ситуация, что x больше, чем a_j , но не больше, чем a_{j-1} , невозможна, так как a_{j-1} не больше, чем a_j , а признать возможной такое положение дел ($a_j < x_k \leq a_{j-1}$) означало бы то, что $a_j < a_{j-1}$

$$\begin{aligned} \begin{cases} \mathbb{1}(x_k \leq a_j) = 0 \\ \mathbb{1}(x_k \leq a_{j-1}) = 1 \\ a_{j-1} \leq a_j \end{cases} &\Rightarrow \begin{cases} x_k > a_j \\ x_k \leq a_{j-1} \\ a_{j-1} \leq a_j \end{cases} \\ &\Rightarrow \begin{cases} a_j < x_k \leq a_{j-1} \\ a_{j-1} \leq a_j \end{cases} \end{aligned}$$

Если оба индикатора равны нулю, то это значит, что x строго больше как a_j , так и a_{j-1} . Опять же, поскольку $a_{j-1} \leq a_j$, то достаточно сказать, что $x > a_j$.

$$\begin{aligned} \begin{cases} \mathbb{1}(x_k \leq a_j) = 0 \\ \mathbb{1}(x_k \leq a_{j-1}) = 0 \\ a_{j-1} \leq a_j \end{cases} &\Rightarrow \begin{cases} x_k > a_j \\ x_k > a_{j-1} \\ a_j \geq a_{j-1} \end{cases} \\ &\Rightarrow x_k > a_j \geq a_{j-1} \Rightarrow x_k > a_j \end{aligned}$$

Если же x больше, чем a_{j-1} , но не больше, чем a_j , то x попадает в полуинтервал $(a_{j-1}, a_j]$

$$\begin{aligned} \begin{cases} \mathbb{1}(x_k \leq a_j) = 1 \\ \mathbb{1}(x_k \leq a_{j-1}) = 0 \\ a_{j-1} \leq a_j \end{cases} &\Rightarrow \begin{cases} x_k \leq a_j \\ x_k > a_{j-1} \\ a_j \geq a_{j-1} \end{cases} \\ &\Rightarrow a_{j-1} < x_k \leq a_j \end{aligned}$$

Вспомним формулу (1.2)

$$\begin{aligned} F_n(a_j) - F_n(a_{j-1}) &= \\ &= \frac{1}{n} \cdot \sum_{k=1}^n [\mathbb{1}(x_k \leq a_j) - \mathbb{1}(x_k \leq a_{j-1})] \end{aligned}$$

Очевидно, что нас интересуют те пары, разность которых не равна нулю. Это значит, что те случаи, когда $x > a_j$ или $x \leq a_{j-1}$, нас не интересуют. Поскольку такой случай, что $a_j < x \leq a_{j-1}$ невозможен, то его тоже отбросим. Значит, остался только тот вариант, когда x попадает в полуинтервал $(a_{j-1}, a_j]$

$$\frac{1}{n} \cdot \sum_{k=1}^n [\mathbb{1}(x_k \leq a_j) - \mathbb{1}(x_k \leq a_{j-1})] = \frac{1}{n} \cdot \sum_{k=1}^n \mathbb{1}(x_k \in (a_{j-1}, a_j])$$

Видим знакомые полуинтервалы $(a_{j-1}, a_j] = I_j$. Воспользуемся этим

$$\frac{1}{n} \cdot \sum_{k=1}^n \mathbb{1}(x_k \in (a_{j-1}, a_j]) = \frac{1}{n} \cdot \sum_{k=1}^n \mathbb{1}(x_k \in I_j)$$

Получаем компактную запись для разности функций распределения

$$F_n(a_j) - F_n(a_{j-1}) = \frac{1}{n} \cdot \sum_{k=1}^n \mathbb{1}(x_k \in I_j) \quad (1.3)$$

Вернёмся к уравнению (1.1)

$$q_n(y) = \sum_{j=1}^m \frac{F_n(a_j) - F_n(a_{j-1})}{a_j - a_{j-1}} \cdot \mathbb{1}(y \in I_j)$$

Воспользовавшись тем, что $(a_j - a_{j-1})$ — длина полуинтервала I_j , а разность $F_n(a_j) - F_n(a_{j-1})$ была только что переписана через индикаторы, получаем такую формулу

$$q_n(y) = \sum_{j=1}^m \frac{1}{n} \sum_{k=1}^n \mathbb{1}(x_k \in I_j) \cdot \frac{1}{|I_j|} \cdot \mathbb{1}(y \in I_j)$$

Упростим, введя функцию $\nu_j(X)$ [1, стр. 68], которая считает количество элементов выборки $X = x_1, \dots, x_n$, попавших в интервал I_j . Это будет сумма индикаторов того, что элемент x_k попал в I_j

$$\nu_j(X) = \sum_{x \in X} \mathbb{1}(x \in I_j) = \sum_{k=1}^n \mathbb{1}(x_k \in I_j)$$

Поскольку $\mathbb{1}(y \in I_j)$ зависит от j и не зависит от k , то его можно перенести во внешнюю сумму. Получаем следующую формулу

$$q_n(y) = \sum_{j=1}^m \frac{\mathbb{1}(y \in I_j)}{n \cdot |I_j|} \cdot \nu_j(X)$$

У этой суммы только один ненулевой элемент, так как y может попасть только в один полуинтервал. Тогда обозначим номер отрезка, в который попал y , через k ($y \in I_k$), а функцию $q_n(y)$ запишем как q_n^k

$$q_n^k = \frac{\nu_k(X)}{n \cdot |I_k|} \quad (1.4)$$

Что мы тут видим? Теперь k — номер “столбика” гистограммы (номер интересующего нас полуинтервала — того, в который попал y).

“Высота” столбика (значение функции на определённом полуинтервале) пропорциональна количеству элементов, попавших в этот отрезок (что логично). Кроме того, происходит деление на общее количество элементов. Деление нужно, чтобы $q(y)$ сходилось к $p(y)$.

Делителю же $|I_k|$ отведена особая роль — он предотвращает искажение гистограммы при различных длинах отрезков. То есть, чем длиннее отрезок, тем ниже столбик, так как элементы более “размазаны” по отрезку, что тоже логично.

Представим, что значение функции — это высота прямоугольника, а длина отрезка — его ширина (графически это изображается именно так). Тогда отношение количества элементов, попавших в полуинтервал, к количеству всех элементов выборки (вероятность того, что случайно взятый элемент из выборки попадёт в k -ый отрезок [1, стр. 24]), является площадью прямоугольника

$$S_k = \frac{\nu_k(X)}{n} = \mathbb{P}_n(x \in I_k)$$

Введём замену в формуле (1.4) и умножим обе части на длину отрезка

$$\mathbb{P}_n(x \in I_k) = q_n^k \cdot |I_k|$$

Если устремить количество полуинтервалов к бесконечности ($m \rightarrow \infty$), то каждый полуинтервал будет сжиматься в точку. При этом вероятность попадания x в отрезок будет стремиться к вероятности попадания x в точку y . Введём обозначения $|I_j| = \delta$, $I_j = \Delta_y$

$$\mathbb{P}_n(x = y) \approx \mathbb{P}_n(x \in \Delta_y) = q_n(y) \cdot \delta, \quad m \rightarrow \infty$$

Очень напоминает ситуацию с плотностью распределения непрерывной случайной величины ξ

$$\mathbb{P}(\xi = x) \approx p(x) \cdot \delta, \quad \delta \rightarrow 0$$

Нужно отметить, что количество элементов выборки должно стремиться к бесконечности ($n \rightarrow \infty$), так как плотность может быть лишь у непрерывных случайных величин. Чем больше будет элементов, тем плотнее они будут стоять на числовой прямой.

1.1.3 Оценка неизвестных параметров

Снова у нас есть x_1, \dots, x_n — выборка из распределения F_θ , где θ — неизвестный параметр из множества Θ

Пример 1.1.3

Имеем нормальное распределение с известным СКО $\sigma = 1$ и неизвестным математическим ожиданием a — $N(a, 1)$. Тогда θ — математическое ожидание a

Пример 1.1.4

Есть нормальное распределение, в котором неизвестны оба параметра. Тогда θ будет парой (a, σ)

Главный вопрос — определение основных параметров распределения выборки.

Определение 1.1.5: Статистика

Статистикой называют функцию S от выборки $X = (x_1, x_2, \dots, x_n)$

$$S(X) = S(x_1, x_2, \dots, x_n)$$

Определение 1.1.6: Оценка

Статистику, значение которой заменяет неизвестный параметр, называют оценкой

Пример 1.1.7

Предположим, что выборка сделана из распределения Бернулли, то есть $\{x_i\}$ — набор одинаково распределённых случайных величин, причём

$$x_i = \begin{cases} 1, & p \\ 0, & 1 - p \end{cases}$$

Тогда неизвестный параметр — величина p (вероятность удачного эксперимента)

$$\theta = p \in [0; 1] = \Theta$$

Введём разные оценки \hat{p}

$$\hat{p}_1 = \frac{1}{n} \sum_{k=1}^n x_k$$

$$\hat{p}_2 = x_1$$

$$\hat{p}_3 = \frac{2}{n} \sum_{k=1}^{\lfloor \frac{n}{2} \rfloor} x_k$$

Замечание: Поскольку \hat{p} — случайная величина, то может оказаться, что она не равна настоящему параметру p

$$\mathbb{P}\{\hat{p} = p\} = 0$$

1. Возникает мысль о том, что разность $\hat{p} - p$ должна быть “маленькой”. Например, чтобы $M(\hat{p} - p)^2$ было самое маленькое из возможных.

2. Также логично желать того, чтобы оценка \hat{p} сходилась к истинному значению параметра p по вероятности ($\hat{p} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} p$) или почти всюду ($\hat{p} \xrightarrow[n \rightarrow \infty]{a.s.} p$)
3. При многократном повторении эксперимента даже самая (на первый взгляд) плохая оценка может оказаться полезной

$$M\hat{p}_1 = p$$

$$M\hat{p}_2 = p$$

$$M\hat{p}_3 = p$$

Например, если целый год каждый день дают набор чисел, а статистик считает значение параметра p с помощью оценки \hat{p}_2 , то в среднем за год у него получится величина, близкая к истинному p .

Определение 1.1.8: Состоятельная оценка

Оценка $\hat{\theta}$ называется состоятельной, если стремится к истинному значению θ по вероятности

$$\hat{\theta} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta$$

Определение 1.1.9: Сильно состоятельная оценка

Оценка $\hat{\theta}$ называется сильно состоятельной, если стремится к истинному значению θ почти наверное

$$\hat{\theta} \xrightarrow[n \rightarrow \infty]{a.s.} \theta$$

Пример 1.1.10

Оценка \hat{p}_1 из прошлого примера является сильно состоятельной.

Определение 1.1.11: Несмещённая оценка

Оценка $\hat{\theta}$ несмещённая, если

$$\forall \theta \in \Theta : M_{\theta} \hat{\theta} = \theta$$

Замечание 1.1.12

Несмещённая оценка существует не всегда

Определение 1.1.13

Несмещённая оценка $\hat{\theta} \in K$ называется оптимальной в классе квадратично интегрируемых оценок K , если для всякой другой несмещённой оценки $\tilde{\theta} \in K$

$$D_{\theta} \hat{\theta} \leq D_{\theta} \tilde{\theta}, \quad \forall \theta \in \Theta$$

или же

$$M_{\theta} (\hat{\theta} - \theta)^2 \leq M_{\theta} (\tilde{\theta} - \theta)^2, \quad \forall \theta \in \Theta$$

Замечание 1.1.14

В учебнике Боровкова А. А. “Математическая статистика” оценка, удовлетворяющая этим условиям, носит название **эффективная оценка** [1, стр. 130], но у нас этот термин будет использоваться далее в другом смысле

Пример 1.1.15

Сравним \hat{p}_1 и \hat{p}_3

$$D_p \hat{p}_1 = \frac{1}{n^2} \cdot n \cdot p \cdot (1-p) = \frac{p \cdot (1-p)}{n}$$

$$D_p \hat{p}_3 = \frac{2 \cdot p \cdot (1-p)}{n}$$

1.1.4 Выборочные оценки. Метод моментов

Как восстановить неизвестный параметр $\theta \in \Theta$ из функции распределения $F_{\theta}(x)$?

Вспомним распределения и их параметры

1. Нормальное распределение $N(a, \sigma^2)$. В нём параметр a является средним, а параметр σ^2 — дисперсией
2. Пуассоновское распределение $Poi(\lambda)$. Тут параметр λ является и средним, и дисперсией
3. Экспоненциальное распределение $Exp(\lambda)$. $\frac{1}{\lambda}$ — среднее, $\frac{1}{\lambda^2}$ — дисперсия

И так далее...

Как правило, неизвестный параметр θ можно искать следующим образом

$$\exists \varphi \in C(\mathbb{R}) : \int_{\mathbb{R}} \varphi(x) dF_{\theta}(x) = g(\theta)$$

Значит, у нас есть уравнение для поиска оценки $\hat{\theta}$ при непрерывной и монотонной $g(\hat{\theta})$

$$g(\hat{\theta}) = \int_{\mathbb{R}} \varphi(x) dF_n(x) \quad (1.5)$$

Пример 1.1.16

Если θ — среднее, то $\varphi(x) = x$

$$\int_{-\infty}^{+\infty} x dF_{\theta}(x) = \theta = g(\theta)$$

Теорема 1.1.17

Пусть функция $\varphi(x)$ в (1.5) непрерывна, ограничена и строго монотонная. Тогда оценка $\hat{\theta}$ существует и является сильно состоятельной.

Доказательство. Имеем формулу (1.5)

$$g(\hat{\theta}) = \int_{\mathbb{R}} \varphi(x) dF_n(x)$$

Поскольку функция $g(\hat{\theta})$ непрерывна и монотонна, то она имеет обратную функцию $g^{-1} : g^{-1}(g(\hat{\theta})) = \hat{\theta}$.

Применим обратную функцию к обеим частям уравнения

$$\hat{\theta} = g^{-1} \left(\int_{\mathbb{R}} \varphi(x) dF_n(x) \right)$$

Поскольку выборочная функция распределения почти всюду равна неизвестной функции распределения при достаточно большом объеме выборки, то

$$\int_{\mathbb{R}} \varphi(x) dF_n(x) \xrightarrow[n \rightarrow \infty]{a.s.} \int_{\mathbb{R}} \varphi(x) dF_n(x)$$

Функция $g^{-1}(x)$ непрерывна

$$\hat{\theta} = g^{-1} \left(\int_{\mathbb{R}} \varphi(x) dF_n(x) \right) \xrightarrow[n \rightarrow \infty]{a.s.} g^{-1} \left(\int_{\mathbb{R}} \varphi(x) dF_n(x) \right) = \theta$$

Теорема доказана

$$\hat{\theta} \xrightarrow[n \rightarrow \infty]{a.s.} \theta$$

□

Определение 1.1.18: Выборочное среднее

Выборочное среднее обозначается через \bar{x} и считается по следующей формуле

$$\bar{x} = \int_{\mathbb{R}} x dF_n(x)$$

Поскольку все элементы выборки равновероятны, получаем математическое ожидание дискретной равномерно распределённой случайной величины, принимающей n значений

$$\bar{x} = \int_{\mathbb{R}} x dF_n(x) = \frac{1}{n} \cdot \sum_{k=1}^n x_k$$

Определение 1.1.19: Выборочная дисперсия

Выборочная дисперсия $\overline{\sigma^2}$ считается по формуле

$$\overline{\sigma^2} = \int_{\mathbb{R}} (x - \bar{x})^2 dF_n(x) = \frac{1}{n} \cdot \sum_{k=1}^n (x_k - \bar{x})^2$$

1.2 Свойства оценок

1.2.1 Неравенство Рао-Крамера

Теорема 1.2.1: Колмогорова

Оптимальная оценка единственная или её нет вообще

Доказательство. Допустим, есть две разные оптимальные и несмещённые оценки θ_1 и θ_2 . Тогда по определению для любой несмещённой оценки $\hat{\theta}$ будет

$$\begin{cases} D_{\theta}\theta_1 \leq D_{\theta}\hat{\theta} \\ D_{\theta}\theta_2 \leq D_{\theta}\hat{\theta} \end{cases}, \forall \theta \in \Theta$$

Поскольку неравенство выполняется для каждой несмещённой оценки $\hat{\theta}$, а оценки θ_1 и θ_2 являются несмещёнными, то можем их и поставить в неравенство в роли $\hat{\theta}$

$$\begin{cases} D_{\theta}\theta_1 \leq D_{\theta}\theta_2 \\ D_{\theta}\theta_2 \leq D_{\theta}\theta_1 \end{cases}, \forall \theta \in \Theta$$

А это возможно только если дисперсии этих оценок равны. Обозначим эту дисперсию через $\sigma^2(\theta)$

$$D_{\theta}\theta_1 = D_{\theta}\theta_2 = \sigma^2(\theta)$$

Возьмём несмещённую оценку $\tilde{\theta}$, равную среднеарифметическому оценок θ_1 и θ_2

$$\tilde{\theta} = \frac{1}{2} \cdot \theta_1 + \frac{1}{2} \cdot \theta_2$$

Тогда по определению θ_1 и θ_2 получаем, что дисперсия новой оценки не меньше, чем у оптимальных

$$D_{\theta}\tilde{\theta} \geq \sigma^2(\theta) \quad (1.6)$$

Попробуем честно вычислить дисперсию оценки $\tilde{\theta}$

$$\begin{aligned} D_{\theta}\tilde{\theta} &= M_{\theta}(\tilde{\theta} - \theta) = M_{\theta}\left[\frac{1}{2} \cdot (\theta_1 - \theta) + \frac{1}{2} \cdot (\theta_2 - \theta)\right]^2 = \\ &= \frac{1}{4} \cdot D_{\theta}\theta_1 + \frac{1}{4} \cdot D_{\theta}\theta_1 + \frac{1}{2} \cdot M_{\theta}[(\theta_1 - \theta) \cdot (\theta_2 - \theta)] \end{aligned}$$

Воспользуемся неравенством Коши (частный случай неравенства Гёльдера)

$$\begin{aligned} M_{\theta}[(\theta_1 - \theta) \cdot (\theta_2 - \theta)] &\leq \sqrt{M_{\theta}(\theta_1 - \theta)^2 \cdot M_{\theta}(\theta_2 - \theta)^2} = \\ &= \sqrt{D_{\theta}\theta_1 \cdot D_{\theta}\theta_2} = \sqrt{\sigma_1^2 \cdot \sigma_2^2} \end{aligned} \quad (1.7)$$

И вернёмся к вычислению дисперсии оценки $\tilde{\theta}$

$$\begin{aligned} \frac{1}{4} \cdot D_{\theta}\theta_1 + \frac{1}{4} \cdot D_{\theta}\theta_1 + \frac{1}{2} \cdot M_{\theta}[(\theta_1 - \theta) \cdot (\theta_2 - \theta)] &\leq \\ &\leq \frac{1}{2} \cdot \sigma^2(\theta) + \frac{1}{2} \cdot \sqrt{\sigma^2(\theta) \cdot \sigma^2(\theta)} = \sigma^2(\theta) \end{aligned}$$

То есть, дисперсия оценки $\tilde{\theta}$ не больше дисперсии введённой оптимальной оценки

$$D_{\theta}\tilde{\theta} \leq \sigma^2(\theta) \quad (1.8)$$

Воспользовавшись неравенствами (1.6) и (1.8), получаем равенство

$$D_{\theta}\tilde{\theta} = \sigma^2(\theta)$$

Это значит, что в неравенстве (1.7) в данном случае тоже выходит равенство

$$M_{\theta}[(\theta_1 - \theta) \cdot (\theta_2 - \theta)] = \sqrt{M_{\theta}(\theta_1 - \theta)^2} \cdot \sqrt{M_{\theta}(\theta_2 - \theta)^2}$$

Для дальнейших размышлений вспомним аналогию с векторами, а именно смысл равенства в неравенстве Коши для скалярного произведения векторов

$$\vec{a} \cdot \vec{b} = |\vec{a}| \cdot |\vec{b}| \cdot \cos(\widehat{\vec{a}, \vec{b}}) = \sqrt{\vec{a}^2} \cdot \sqrt{\vec{b}^2} \cdot \cos(\widehat{\vec{a}, \vec{b}})$$

Скалярное произведение двух векторов равно произведению их модулей только тогда, когда они сонаправлены

$$\left(\widehat{\vec{a}, \vec{b}}\right) = 0 \Rightarrow \vec{a} \cdot \vec{b} = \sqrt{\vec{a}^2} \cdot \sqrt{\vec{b}^2}$$

Положим математическое ожидание нормой, а $\theta_1 - \theta$ и $\theta_2 - \theta$ векторами пространства случайных событий. Получаем, что нормы и направления этих векторов совпадают

$$\begin{aligned} M_\theta [(\theta_1 - \theta) \cdot (\theta_2 - \theta)] &= \sqrt{M_\theta (\theta_1 - \theta)^2} \cdot \sqrt{M_\theta (\theta_2 - \theta)^2} \\ &\Rightarrow \left(\widehat{\theta_1 - \theta, \theta_2 - \theta}\right) \end{aligned}$$

Это значит, что они равны, что противоречит предположению о том, что они разные

$$\begin{aligned} \begin{cases} \left(\widehat{\theta_1 - \theta, \theta_2 - \theta}\right) = 0 \\ M_\theta (\theta_1 - \theta)^2 = M_\theta (\theta_2 - \theta)^2 \end{cases} &\Rightarrow \theta_1 - \theta = \theta_2 - \theta \\ &\Rightarrow \theta_1 = \theta_2 \end{aligned}$$

Теорема доказана □

Для дальнейших действий будем считать, что функция распределения $F_\theta(x)$ имеет плотность $p(x, \theta)$, которая дважды дифференцируема по θ . То есть её можно дифференцировать под знаком интеграла.

Также отметим, что выборка (x_1, \dots, x_n) имеет плотность распределения, так как является случайным вектором в \mathbb{R}^n , все компоненты которого — случайные величины.

Определение 1.2.2: Функция правдоподобия

Плотность распределения вектора независимых случайных величин, равная произведению плотностей распределения его компонент, называется функцией правдоподобия

$$L(\vec{x}, \theta) = \prod_{k=1}^n p(x_k, \theta)$$

Прологарифмировав функцию правдоподобия, получим симпатичную сумму

$$\ln L(\vec{x}, \theta) = \sum_{k=1}^n \ln p(x_k, \theta)$$

А симпатична она тем, что это сумма незасимых одинаково распределённых случайных величин. Воспользовавшись законом больших чисел, можем

сказать, что она стремится к сумме n одинаковых математических ожиданий при достаточно большом размере выборки

$$\begin{aligned}\ln L(\vec{x}, \theta) &= n \cdot \frac{\ln p(x_1, \theta) + \dots + \ln p(x_n, \theta)}{n} \approx \\ &\approx n \cdot M_\theta \ln p(x_1, \theta)\end{aligned}$$

Проблема в том, что мы не знаем среднего. Для разрешения этого вопроса введём ещё одно определение

Определение 1.2.3: Вклад выборки

Вклад выборки — частная производная по параметру θ от логарифма функции правдоподобия

$$\begin{aligned}U(\vec{x}, \theta) &= \frac{\partial}{\partial \theta} \ln L(\vec{x}, \theta) = \sum_{k=1}^n \frac{\partial}{\partial \theta} \cdot \ln p(x_k, \theta) \\ &= \frac{\frac{\partial}{\partial \theta} L(\vec{x}, \theta)}{L(\vec{x}, \theta)}\end{aligned}$$

Замечание 1.2.4

Математическое ожидание вклада выборки равно нулю

$$M_\theta U(\vec{x}, \theta) = 0$$

Доказательство. Посчитаем математическое ожидание вклада выборки

$$\begin{aligned}M_\theta U(\vec{x}, \theta) &= \int_{\mathbb{R}^n} U(\vec{u}, \theta) \cdot L(\vec{u}, \theta) d\vec{u} = \\ &= \int_{\mathbb{R}^n} \frac{\frac{\partial}{\partial \theta} L(\vec{x}, \theta)}{L(\vec{x}, \theta)} \cdot L(\vec{u}, \theta) d\vec{u} = \\ &= \int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} L(\vec{u}, \theta) d\vec{u}\end{aligned}$$

Воспользовавшись предположением о том, что функция распределения дважды дифференцируема, вынесем взятие производной за знак интеграла

$$M_\theta U(\vec{x}, \theta) = \frac{\partial}{\partial \theta} \int_{\mathbb{R}^n} L(\vec{u}, \theta) d\vec{u}$$

Поскольку интегрируем плотность распределения случайного вектора по всему пространству, то он равен единице. Производная же от единицы равна нулю. Это значит, что математическое ожидание вклада выборки

равно нулю

$$M_{\theta} U(\vec{x}, \theta) = \frac{\partial}{\partial \theta} \int_{\mathbb{R}^n} L(\vec{u}, \theta) d\vec{u} = \frac{\partial}{\partial \theta} 1 = 0$$

□

Замечание 1.2.5

Частная производная по оценке θ от функции правдоподобия $L(\vec{u}, \theta)$ равна нулю.

Доказательство. Выше у нас было равенство

$$\frac{\partial}{\partial \theta} \int_{\mathbb{R}^n} L(\vec{u}, \theta) d\vec{u} = 0$$

Так как производную можем заносить под знак интеграла (согласно нашему предположению), то получаем такое равенство

$$\int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} L(\vec{u}, \theta) d\vec{u} = 0$$

Поскольку интеграл не зависит от θ , то такое возможно лишь в том случае, когда производная равна нулю

$$\frac{\partial}{\partial \theta} L(\vec{u}, \theta) = 0$$

□

Определение 1.2.6: Количество информации Фишера

Математическое ожидание квадрата вклада выборки называется количеством информации Фишера

$$I_n(\theta) = M_{\theta} U(\vec{x}, \theta)^2$$

Замечание 1.2.7

$$M_{\theta} U(\vec{x}, \theta)^2 = -M_{\theta} \frac{\partial^2}{\partial \theta^2} \ln L(\vec{x}, \theta)$$

Доказательство. Будем доказывать справа налево

$$\begin{aligned} -M_\theta \frac{\partial^2}{\partial \theta^2} \ln L(\vec{x}, \theta) &= -M_\theta \frac{\partial}{\partial \theta} \frac{\frac{\partial}{\partial \theta} L(\vec{x}, \theta)}{L(\vec{x}, \theta)} = \\ &= -M_\theta \left(\frac{\frac{\partial^2}{\partial \theta^2} L(\vec{x}, \theta) \cdot L(\vec{x}, \theta) - \left[\frac{\partial}{\partial \theta} L(\vec{x}, \theta) \right]^2}{L(\vec{x}, \theta)^2} \right) = \\ &= -M_\theta \frac{\frac{\partial^2}{\partial \theta^2} L(\vec{x}, \theta)}{L(\vec{x}, \theta)} + M_\theta \left[\frac{\frac{\partial}{\partial \theta} L(\vec{x}, \theta)}{L(\vec{x}, \theta)} \right]^2 \end{aligned}$$

Помним, что производная от функции правдоподобия по θ равна нулю. Значит вторая производная тоже равна нулю и остаётся лишь математическое ожидание квадрата, который равен квадрату производной логарифма функции правдоподобия, что в свою очередь и есть вклад выборки

$$\begin{aligned} \frac{\partial}{\partial \theta} L(\vec{u}, \theta) = 0 &\Rightarrow -M_\theta \frac{\frac{\partial^2}{\partial \theta^2} L(\vec{x}, \theta)}{L(\vec{x}, \theta)} = 0 \\ \Rightarrow -M_\theta \frac{\partial^2}{\partial \theta^2} \ln L(\vec{x}, \theta) &= M_\theta \left[\frac{\frac{\partial}{\partial \theta} L(\vec{x}, \theta)}{L(\vec{x}, \theta)} \right]^2 = \\ &= M_\theta \left[\frac{\partial}{\partial \theta} \ln L(\vec{x}, \theta) \right]^2 = M_\theta U(\vec{x}, \theta)^2 \end{aligned}$$

Утверждение доказано

$$M_\theta U(\vec{x}, \theta)^2 = -M_\theta \frac{\partial^2}{\partial \theta^2} \ln L(\vec{x}, \theta)$$

□

Количество информации позволяет оценить точность, с которой можем получить параметр θ

Теорема 1.2.8: Неравенство Рао-Крамера

Пусть $\hat{\theta}$ — несмещённая оценка параметра θ . Тогда имеет место неравенство

$$\forall \theta \in \Theta : D_\theta \hat{\theta} \geq \frac{1}{I_n(\theta)}$$

Доказательство. Выпишем, чему равно математическое ожидание оценки θ

$$\begin{aligned} \begin{cases} M_\theta \hat{\theta} &= \theta \\ M_\theta \hat{\theta} &= \int_{\mathbb{R}^n} \hat{\theta}(\vec{u}) \cdot L(\vec{u}, \theta) d\vec{u} \end{cases} \\ \Rightarrow \theta &= \int_{\mathbb{R}^n} \hat{\theta}(\vec{u}) \cdot L(\vec{u}, \theta) d\vec{u} \end{aligned}$$

Продифференцируем с двух сторон полученное для θ равенство по самому параметру θ

$$\frac{\partial}{\partial \theta} \theta = \frac{\partial}{\partial \theta} \int_{\mathbb{R}^n} \hat{\theta}(\vec{u}) \cdot L(\vec{u}, \theta) d\vec{u}$$

Левая часть равенства превращается в единицу, а справа заносим взятие производной под знак интеграла. Также помним, что оценка $\theta(\vec{u})$ не зависит от параметра θ . Это значит, что производную нужно брать только от функции правдоподобия

$$1 = \int_{\mathbb{R}^n} \hat{\theta}(\vec{u}) \cdot \frac{\partial}{\partial \theta} L(\vec{u}, \theta) d\vec{u}$$

Далее нам нужно получить вклад выборки. Для этого умножим и поделим подинтегральное выражение на функцию правдоподобия

$$\begin{aligned} & \int_{\mathbb{R}^n} \hat{\theta}(\vec{u}) \cdot \frac{\partial}{\partial \theta} L(\vec{u}, \theta) d\vec{u} = \\ & = \int_{\mathbb{R}^n} \hat{\theta}(\vec{u}) \cdot \frac{\frac{\partial}{\partial \theta} L(\vec{u}, \theta)}{L(\vec{u}, \theta)} \cdot L(\vec{u}, \theta) d\vec{u} \end{aligned}$$

Видим, что дробь под интегралом — производная логарифма функции правдоподобия, которая является вкладом выборки

$$\begin{aligned} & \int_{\mathbb{R}^n} \hat{\theta}(\vec{u}) \cdot \frac{\frac{\partial}{\partial \theta} L(\vec{u}, \theta)}{L(\vec{u}, \theta)} \cdot L(\vec{u}, \theta) d\vec{u} = \\ & = \int_{\mathbb{R}^n} \hat{\theta}(\vec{u}) \cdot U(\vec{x}, \theta) \cdot L(\vec{u}, \theta) d\vec{u} \end{aligned}$$

У нас есть математическое ожидание произведения оценки и вклада выборки, которое равно единице

$$1 = M_{\theta} \left(\hat{\theta} \cdot U(\vec{x}, \theta) \right) \quad (1.9)$$

Помним, что математическое ожидание вклада выборки равно нулю. Значит, умножение его на константу ничего не меняет

$$\begin{aligned} & M_{\theta} U(\vec{x}, \theta) = 0 \\ \Rightarrow & \theta \cdot M_{\theta} U(\vec{x}, \theta) = M_{\theta} (\theta \cdot U(\vec{x}, \theta)) = 0 \end{aligned}$$

Воспользовавшись полученным результатом, вернёмся к равенству (1.9). Отнимем от обеих частей ноль (то есть, полученное только что выражение)

$$1 = M_{\theta} \left(\hat{\theta} \cdot U(\vec{x}, \theta) \right) - M_{\theta} (\theta \cdot U(\vec{x}, \theta))$$

Получаем компактное равенство

$$1 = M_{\theta} \left[\left(\hat{\theta} - \theta \right) \cdot U(\vec{x}, \theta) \right]$$

Воспользовавшись неравенством Коши, узнаём, произведение корней дисперсии и количества информации больше, чем единица

$$\begin{aligned}
 1 &= M_\theta \left[\left(\hat{\theta} - \theta \right) \cdot U(\vec{x}, \theta) \right] \leq \\
 &\leq \sqrt{M_\theta \left(\hat{\theta} - \theta \right)} \cdot \sqrt{M_\theta U(\vec{x}, \theta)} = \\
 &= \sqrt{D_\theta \hat{\theta}} \cdot \sqrt{I_n(\theta)}
 \end{aligned} \tag{1.10}$$

Возводим обе части равенства в квадрат и делим на количество информации

$$D_\theta \hat{\theta} \geq \frac{1}{I_n(\theta)}$$

Неравенство доказано □

Замечание 1.2.9

Иногда нужно оценивать не сам параметр, а функцию параметра

Если α — несмещённая оценка для $f(\theta)$, то справедливо следующее неравенство

$$\forall \theta \in \Theta : D_\theta \alpha \geq \frac{|f'(\theta)|}{I_n(\theta)}$$

1.2.2 Метод максимального правдоподобия

У нас есть нижняя оценка точности, с которой можно отыскать желаемую оценку, а это значит, что точнее определить просто не получится и нужно стремиться к равенству в неравенстве Рао-Крамера.

Определение 1.2.10: Эффективная оценка

Оценка $\hat{\theta}$, для которой в неравенстве Рао-Крамера стоит равенство, называется эффективной

$$\forall \theta \in \Theta : D_\theta \hat{\theta} = \frac{1}{I_n(\theta)}$$

Попытаемся выяснить, какими свойствами должна обладать плотность, чтобы можно было получить эффективную оценку. Для этого в неравенстве Рао-Крамера нужно рассмотреть случай равенства (так как в этом случае оценка будет самой точной)

$$D_\theta \hat{\theta} = \frac{1}{I_n(\theta)}$$

Рассмотрим неравенство (1.10) и попытаемся понять, в каком случае в нём будет стоять знак равенства

$$\begin{aligned} 1 &= M_\theta \left[\left(\hat{\theta} - \theta \right) \cdot U(\vec{x}, \theta) \right] = \\ &= \sqrt{M_\theta \left(\hat{\theta} - \theta \right)^2} \cdot \sqrt{M_\theta U(\vec{x}, \theta)^2} \end{aligned}$$

Снова проводим аналогию с векторами и видим, что скалярное произведение (математическое ожидание произведения) векторов (функций от параметра θ : $f_1(\theta) = \hat{\theta} - \theta$ и $f_2(\theta) = U(\vec{x}, \theta)$) равно произведению их норм (корней математических ожиданий квадратов).

Это в свою очередь означает, что “угол” между этими векторами (функциями) равен нулю и эти функции являются линейными комбинациями друг друга. Значит, есть такая функция $k(\theta)$, что $f_2(\theta)$ равняется произведению $f_1(\theta)$ и $k(\theta)$.

$$\begin{aligned} U(\vec{x}, \theta) &= \left(\hat{\theta} - \theta \right) \cdot k(\theta) \\ \frac{\partial}{\partial \theta} \ln L(\vec{x}, \theta) &= \hat{\theta} \cdot k(\theta) - \theta \cdot k(\theta) \\ \partial \ln L(\vec{x}, \theta) &= \hat{\theta}(\vec{x}) \cdot k(\theta) \cdot \partial \theta - \theta \cdot k(\theta) \cdot \partial \theta \end{aligned}$$

Проинтегрируем обе части равенства

$$\int \partial \ln L(\vec{x}, \theta) = \hat{\theta}(\vec{x}) \cdot \int k(\theta) \partial \theta - \int \theta \cdot k(\theta) \partial \theta$$

Получим следующее равенство

$$\ln L(\vec{x}, \theta) + c_1(\vec{x}) = \hat{\theta}(\vec{x}) \cdot [a(\theta) + c_2] - [b^*(\theta) + c_3]$$

Сгруппируем константы и введём замену $b(\theta) = -b^*(\theta)$

$$\ln L(\vec{x}, \theta) = \hat{\theta}(\vec{x}) \cdot a(\theta) + b(\theta) + c(\vec{x})$$

Избавимся от логарифма слева, а для этого проэкспонируем обе части равенства

$$L(\vec{x}, \theta) = \exp \left\{ \hat{\theta}(\vec{x}) \cdot a(\theta) + b(\theta) + c(\vec{x}) \right\}$$

При конечном n положим такую плотность распределения

$$p(x_1, \theta) = \exp \left\{ \hat{\theta}(x_1) \cdot a_1(\theta) + b_1(\theta) + c_1(x_1) \right\}$$

В таком случае получим следующую функцию правдоподобия

$$\begin{aligned} L(\vec{x}, \theta) &= \prod_{k=1}^n p(x_k, \theta) = \\ &= \exp \left\{ \sum_{k=1}^n \hat{\theta}(x_k) \cdot a_1(\theta) + n \cdot b_1(\theta) + \sum_{k=1}^n c_1(x_k) \right\} \end{aligned}$$

Отметим, что в этом случае оценка $\hat{\theta}(\vec{x})$ является суммой оценок по каждой координате (случайной величине)

$$\hat{\theta}(\vec{x}) = \sum_{k=1}^n \hat{\theta}(x_k)$$

Определение 1.2.11: Экспоненциальное распределение

Распределения следующего вида называются экспоненциальными

$$p(x, \theta) = \exp \left\{ \hat{\theta}(x) \cdot a(\theta) + b(\theta) + c(x) \right\}$$

Попробуем найти рецепт выяснения эффективной оценки. Начнём с примера

Пример 1.2.12

Есть выборка x_1, x_2, \dots, x_n из нормального распределения с неизвестным математическим ожиданием $N(\theta, 1)$. Тогда плотность распределения k -ой случайной величины будет следующей

$$p(x_k) = \frac{1}{\sqrt{2 \cdot \pi}} \cdot \exp \left\{ -\frac{(x_k - \theta)^2}{2} \right\}$$

Её логарифм, очевидно, имеет такой вид

$$\ln p(x_k) = \ln \frac{1}{\sqrt{2 \cdot \pi}} - \frac{(x_k - \theta)^2}{2}$$

Теперь выпишем логарифм функции правдоподобия

$$\begin{aligned} \ln L(\vec{x}, \theta) &= \sum_{k=1}^n \ln p(x_k) = \\ &= \sum_{k=1}^n \ln \frac{1}{\sqrt{2 \cdot \pi}} - \sum_{k=1}^n \frac{(x_k - \theta)^2}{2} = \\ &= n \cdot \ln \frac{1}{\sqrt{2 \cdot \pi}} - \sum_{k=1}^n \frac{(x_k - \theta)^2}{2} \end{aligned}$$

Раскроем скобки

$$\ln L(\vec{x}, \theta) = n \cdot \ln \frac{1}{\sqrt{2 \cdot \pi}} - \sum_{k=1}^n \frac{x_k^2}{2} + \sum_{k=1}^n x_k \cdot \theta - \frac{n \cdot \theta^2}{2}$$

Воспользуемся формулой для несмещённой и эффективной оценки

среднего

$$\sum_{k=1}^n x_k \cdot \theta = \left(\frac{1}{n} \cdot \sum_{k=1}^n x_k \right) \cdot \theta \cdot n = \bar{x} \cdot \theta \cdot n$$

$$\Rightarrow \ln L(\vec{x}, \theta) = n \cdot \ln \frac{1}{\sqrt{2 \cdot \pi}} - \sum_{k=1}^n \frac{x_k^2}{2} + \bar{x} \cdot \theta \cdot n - \frac{n \cdot \theta^2}{2}$$

Сгруппировав множители при n , получаем

$$\ln L(\vec{x}, \theta) = n \cdot \ln \frac{1}{\sqrt{2 \cdot \pi}} - \sum_{k=1}^n \frac{x_k^2}{2} - n \cdot \frac{\theta^2 - 2 \cdot \bar{x} \cdot \theta}{2}$$

Добавим и вычтем в числителе дроби выборочное среднее

$$\ln L(\vec{x}, \theta) = n \cdot \ln \frac{1}{\sqrt{2 \cdot \pi}} - \sum_{k=1}^n \frac{x_k^2}{2} - n \cdot \frac{\theta^2 - 2 \cdot \bar{x} \cdot \theta + (\bar{x}^2 - \bar{x}^2)}{2}$$

Теперь в числителе очевиден квадрат разности

$$\ln L(\vec{x}, \theta) = n \cdot \ln \frac{1}{\sqrt{2 \cdot \pi}} - \sum_{k=1}^n \frac{x_k^2}{2} + n \cdot \frac{\bar{x}^2}{2} - n \cdot \frac{\theta^2 - 2 \cdot \bar{x} \cdot \theta + \bar{x}^2}{2}$$

Сворачиваем квадрат разности, а выборочное среднее заносим под знак суммы

$$\ln L(\vec{x}, \theta) = n \cdot \ln \frac{1}{\sqrt{2 \cdot \pi}} - \sum_{k=1}^n \frac{x_k^2 - \bar{x}^2}{2} - n \cdot \frac{(\theta - \bar{x})^2}{2}$$

Видим, что последнее слагаемое не может быть положительным, так как это квадрат со знаком “минус”. Когда оценка θ равна выборочному среднему (идеальный случай), то последнее слагаемое обращается в нуль, а сама функция правдоподобия в таком случае принимает максимальное значение.

Делаем предположение о том, как находить наилучшую оценку

$$Q_* = \arg \max_{\theta} \ln L(\vec{x}, \theta)$$

Оказывается, именно так она и находится.

Определение 1.2.13: Оценка максимального правдоподобия

Оценка максимального правдоподобия θ_* — такое значение параметра θ , при котором функция правдоподобия достигает своего максимального значения

$$Q_* = \arg \max_{\theta} \ln L(\vec{x}, \theta)$$

Замечание 1.2.14

Оценок максимального правдоподобия может быть несколько, а может не существовать ни одной.

Определение 1.2.15: Уравнение правдоподобия

Уравнением правдоподобия называется равенство вида

$$U(\vec{x}, \theta) = 0$$

Или же

$$\frac{\partial}{\partial \theta} \ln L(\vec{x}, \theta) = 0$$

Замечание 1.2.16

В гладком случае оценку θ_* можно искать с помощью уравнения правдоподобия. Тем не менее, нужно помнить, что равенство первой производной нулю является лишь необходимым условием максимума, поэтому полученные результаты необходимо проверять.

Определение 1.2.17: Вариационный ряд

Вариационный ряд выборки x_1, x_2, \dots, x_n — значения выборки, упорядоченные в порядке неубывания

$$x_{(1)}, x_{(2)}, \dots, x_{(n)}, \quad x_{(1)} = \min_k x_k$$

Теорема 1.2.18

Если плотность $p(x, \theta)$ непрерывна и дифференцируема по параметру θ , а производная не равна нулю $\frac{\partial}{\partial \theta} p(x, \theta) \neq 0$, то оценка максимального правдоподобия состоятельна

Глава 2

Достаточные статистики

2.1 Оптимальная оценка

Определение 2.1.1: Симметризация

Симметризация Λ оценки $\hat{\theta}$ — среднее оценок $\hat{\theta}$ для всевозможных перестановок $\sigma \in S_n$ элементов выборки x_1, x_2, \dots, x_n

$$\Lambda \hat{\theta} = \frac{1}{n!} \cdot \sum_{\sigma \in S_n} \hat{\theta}(x_{\sigma(1)}, x_{\sigma(2)}, \dots, x_{\sigma(n)})$$

Лемма 2.1.2

Для произвольной несмещённой оценки $\hat{\theta}$ её симметризация $\Lambda \hat{\theta}$ не хуже её самой в среднем квадратическом

$$M_{\theta} \hat{\theta} = \theta \Rightarrow \begin{cases} M_{\theta} \Lambda \hat{\theta} = M_{\theta} \hat{\theta} = \theta \\ D_{\theta} \Lambda \hat{\theta} \leq D_{\theta} \hat{\theta} \end{cases}$$

Доказательство. Берём x_1, x_2, \dots, x_n — независимые одинаково распределённые случайные величины.

Введём обозначения для более короткой записи используемых в доказательстве случайных векторов.

Вектор, состоящий из элементов выборки в их изначальном порядке, обозначим привычным \vec{x}

$$(x_1, x_2, \dots, x_n) = \vec{x}$$

Вектор, состоящий из элементов, изменивших своё местоположение под влиянием перестановки σ (значение которой будет ясно из контекста), будем обозначать через \vec{x}_{σ}

$$(x_{\sigma(1)}, x_{\sigma(2)}, \dots, x_{\sigma(n)}) = \vec{x}_{\sigma}$$

Тогда и оценки примут более красивый вид

$$\begin{aligned}\hat{\theta}(x_1, x_2, \dots, x_n) &= \hat{\theta}(\vec{x}) \\ \hat{\theta}(x_{\sigma(1)}, x_{\sigma(2)}, \dots, x_{\sigma(n)}) &= \hat{\theta}(\vec{x}_\sigma)\end{aligned}$$

Теперь приступим непосредственно к доказательству.

1. Начнём с первого пункта — докажем несмещённость симметризации оценки $\hat{\theta}$.

Нетрудно показать, что вектора \vec{x} и \vec{x}_σ имеют одинаковое распределение для любой перестановки σ , а это значит, что и оценки $\hat{\theta}(\vec{x})$ и $\hat{\theta}(\vec{x}_\sigma)$ распределены одинаково как функции случайных одинаково распределённых векторов. Следовательно, их математические ожидания равны между собой при любой перестановке σ

$$M_\theta \hat{\theta}(\vec{x}) = M_\theta \hat{\theta}(\vec{x}_\sigma) = \theta$$

Посчитаем математическое ожидание симметризации оценки $\hat{\theta}$

$$M_\theta \Lambda \hat{\theta} = M_\theta \left\{ \frac{1}{n!} \cdot \sum_{\sigma \in S_n} \hat{\theta}(\vec{x}_\sigma) \right\}$$

Помним, что математическое ожидание линейно и константы можно выносить за знак математического ожидания, а математическое ожидание суммы равно сумме математических ожиданий

$$M_\theta \left\{ \frac{1}{n!} \cdot \sum_{\sigma \in S_n} \hat{\theta}(\vec{x}_\sigma) \right\} = \frac{1}{n!} \cdot \sum_{\sigma \in S_n} M_\theta \hat{\theta}(\vec{x}_\sigma)$$

Не забываем, что математическое ожидание оценки любого вектора \vec{x}_σ одинаково и равно параметру θ

$$\frac{1}{n!} \cdot \sum_{\sigma \in S_n} M_\theta \hat{\theta}(\vec{x}_\sigma) = \frac{1}{n!} \cdot \sum_{\sigma \in S_n} \theta$$

Сумма имеет $n!$ слагаемых (количество перестановок $\sigma \in S_n$)

$$\frac{1}{n!} \cdot \sum_{\sigma \in S_n} \theta = \frac{1}{n!} \cdot n! \cdot \theta = \theta$$

А это значит, что первый пункт доказан и симметризация несмещённой оценки $\hat{\theta}$ действительно несмещённая

$$M_\theta \Lambda \hat{\theta} = \theta$$

2. Теперь посмотрим, чему равна дисперсия симметризации оценки $\hat{\theta}$

Воспользуемся определением

$$D_\theta \Lambda \hat{\theta} = M_\theta \left(\Lambda \hat{\theta} - \theta \right)^2 = M_\theta \left\{ \frac{1}{n!} \cdot \sum_{\sigma \in S_n} \hat{\theta}(\vec{x}_\sigma) - \theta \right\}^2$$

Внесём параметр θ в сумму. Для этого нужно умножить и поделить его на $n!$ (так как сумма имеет $n!$ слагаемых)

$$\begin{aligned} & M_\theta \left\{ \frac{1}{n!} \cdot \sum_{\sigma \in S_n} \hat{\theta}(\vec{x}_\sigma) - \theta \right\}^2 = \\ & = M_\theta \left\{ \frac{1}{n!} \cdot \sum_{\sigma \in S_n} \hat{\theta}(\vec{x}_\sigma) - \frac{1}{n!} \cdot n! \cdot \theta \right\}^2 = \\ & = M_\theta \left\{ \frac{1}{n!} \cdot \left(\sum_{\sigma \in S_n} \hat{\theta}(\vec{x}_\sigma) - n! \cdot \theta \right) \right\}^2 = \\ & = M_\theta \left\{ \frac{1}{n!} \cdot \sum_{\sigma \in S_n} \left(\hat{\theta}(\vec{x}_\sigma) - \theta \right) \right\}^2 = \\ & = M_\theta \left\{ \sum_{\sigma \in S_n} \frac{1}{n!} \cdot \left(\hat{\theta}(\vec{x}_\sigma) - \theta \right) \right\}^2 \end{aligned}$$

Вспомним неравенство Йенсена для выпуклой функции f

$$f \left(\sum_{i=1}^n q_i \cdot x_i \right) \leq \sum_{i=1}^n q_i \cdot f(x_i), \quad \sum_{i=1}^n q_i = 1$$

В нашем случае $x_i = \left(\hat{\theta}(\vec{x}_{\sigma_i}) - \theta \right)$, функция $f(x) = x^2$, сумма проходит по всевозможным перестановкам σ , а роль q_i выполняет $\frac{1}{n!}$, так как

$$\sum_{\sigma \in S_n} q_i = \sum_{\sigma \in S_n} \frac{1}{n!} = n! \cdot \frac{1}{n!} = 1$$

Перепишем неравенство Йенсена для нашего случая

$$M_\theta \left\{ \sum_{\sigma \in S_n} \frac{1}{n!} \cdot \left(\hat{\theta}(\vec{x}_\sigma) - \theta \right) \right\}^2 \leq M_\theta \sum_{\sigma \in S_n} \frac{1}{n!} \cdot \left(\hat{\theta}(\vec{x}_\sigma) - \theta \right)^2 \quad (2.1)$$

Воспользуемся линейностью математического ожидания, внося его под знак суммы

$$M_\theta \sum_{\sigma \in S_n} \frac{1}{n!} \cdot \left(\hat{\theta}(\vec{x}_\sigma) - \theta \right)^2 = \frac{1}{n!} \cdot \sum_{\sigma \in S_n} M_\theta \left(\hat{\theta}(\vec{x}_\sigma) - \theta \right)^2$$

Видим сумму дисперсий. Дисперсии одинаковы, так как оценки имеют одинаковые распределения

$$\begin{aligned} \frac{1}{n!} \cdot \sum_{\sigma \in S_n} M_{\theta} \left(\hat{\theta}(\vec{x}_{\sigma}) - \theta \right)^2 &= \frac{1}{n!} \cdot \sum_{\sigma \in S_n} D_{\theta} \hat{\theta}(\vec{x}_{\sigma}) = \\ &= \frac{1}{n!} \cdot \sum_{\sigma \in S_n} D_{\theta} \hat{\theta}(\vec{x}) = \frac{1}{n!} \cdot n! \cdot D_{\theta} \hat{\theta}(\vec{x}) = D_{\theta} \hat{\theta}(\vec{x}) \end{aligned}$$

Из неравенства Йенсена (2.1) видим, что дисперсия симметризации не хуже дисперсии самой оценки

$$D_{\theta} \Lambda \hat{\theta} \leq D_{\theta} \hat{\theta}(\vec{x})$$

То есть, симметризация не ухудшает оценку, а в общем случае (когда неравенство строгое) даже делает её лучше. \square

Замечание 2.1.3

Равенство в неравенстве Йенсена (в доказательстве выше) возможно только в случае симметричной функции. Значит, в качестве оценки достаточно брать только симметричные функции выборки

Определение 2.1.4: Функция вариационного ряда

Если оценка $\hat{\theta}$ симметрична относительно перестановок аргументов, то она является функцией вариационного ряда

Замечание 2.1.5

Все оценки, которые претендуют быть оптимальными, должны быть функциями вариационного ряда

2.2 σ -алгебра, порождённая случайной величиной

Имеем вероятностное пространство $(\Omega, \mathfrak{F}, \mathbb{P})$, также есть функция $\xi : \Omega \rightarrow \mathbb{R}$ такая, что связанные с ней множества измеримы по Лебегу

$$\{\omega \mid \xi(\omega) < c\} \in \mathfrak{F}, c \in \mathbb{R}$$

Но это будет неудобно при использовании, поэтому возьмём борелевские подмножества \mathfrak{B} множества \mathbb{R}

$$\mathbb{R} \supset \mathfrak{B} \ni \Delta : \xi^{-1}(\Delta) \in \mathfrak{F}$$

Рассмотрим более подробно, что же означает запись $\xi^{-1}(\Delta)$

$$\xi^{-1}(\Delta) = \{\omega \mid \xi(\omega) \in \Delta\}, \quad \Delta \in \mathfrak{B}, \omega \in \Omega$$

Определение 2.2.1: Сигма-алгебра, порождённая случайной величиной

$\mathfrak{F}_\xi = \sigma(\xi)$ — σ -алгебра, порождённая случайной величиной ξ

$$\mathfrak{F}_\xi = \{\xi^{-1}(\Delta) \mid \Delta \in \mathfrak{B}\}$$

Из курса теории вероятностей помним лемму, которая утверждает, что ξ — случайная величина тогда и только тогда, когда

$$\forall \Delta \in \mathfrak{B} : \{\omega \mid \xi(\omega) \in \Delta\} = \{\xi \in \Delta\} = \xi^{-1}(\Delta) \in \mathfrak{F}$$

А это значит, что все элементы σ -алгебры \mathfrak{F}_ξ входят в σ -алгебру \mathfrak{F} , а сама \mathfrak{F}_ξ является подмножеством \mathfrak{F}

$$\begin{cases} \mathfrak{F}_\xi = \{\xi^{-1}(\Delta) \mid \Delta \in \mathfrak{B}\} \\ \forall \Delta \in \mathfrak{B} : \xi^{-1}(\Delta) \in \mathfrak{F} \end{cases} \Rightarrow \mathfrak{F}_\xi \subset \mathfrak{F}$$

Проверим, что \mathfrak{F}_ξ действительно является σ -алгеброй

1. Множество элементарных исходов Ω входит в \mathfrak{F}_ξ . Поскольку случайная величина ξ принимает действительные значения, то прообраз множества действительных чисел \mathbb{R} и будет множеством элементарных исходов Ω . А поскольку \mathbb{R} принадлежит борелевской σ -алгебре, то его прообраз по определению принадлежит σ -алгебре \mathfrak{F}_ξ

$$\begin{cases} \xi^{-1}(\Delta \in \mathfrak{B}) \in \mathfrak{F} \\ \mathbb{R} \in \mathfrak{B} \\ \xi^{-1}(\mathbb{R}) = \Omega \end{cases} \Rightarrow \Omega \in \mathfrak{F}_\xi$$

2. Если событие A принадлежит \mathfrak{F}_ξ , то его дополнение \bar{A} тоже принадлежит \mathfrak{F}_ξ

$$\begin{aligned} A &= \xi^{-1}(\Delta) = \{\omega \mid \xi(\omega) \in \Delta\} \\ \Rightarrow \bar{A} &= \{\omega \mid \xi(\omega) \notin \Delta\} = \{\omega \mid \xi(\omega) \in \bar{\Delta}\} \\ \bar{A} &= \xi^{-1}(\bar{\Delta}) \end{aligned}$$

Поскольку \mathfrak{B} является σ -алгеброй, а Δ — её элемент, то дополнение $\bar{\Delta}$ тоже принадлежит σ -алгебре \mathfrak{B} . Из этого следует, что свойство выполняется

$$\begin{cases} \xi^{-1}(\Delta) \in \mathfrak{F} \\ \Delta \in \mathfrak{B} \Rightarrow \bar{\Delta} \in \mathfrak{B} \end{cases} \Rightarrow \overline{\xi^{-1}(\Delta)} = \xi^{-1}(\bar{\Delta}) \in \mathfrak{F}$$

3. Замкнутость относительно счётных пересечений.

Начнём с замкнутости относительно пересечения двух множеств

$$A = \xi^{-1}(\Delta_1), B = \xi^{-1}(\Delta_2)$$

Начинаем считать

$$\begin{aligned} A \cap B &= \xi^{-1}(\Delta_1) \cap \xi^{-1}(\Delta_2) = \\ &= \{\omega \mid \xi(\omega) \in \Delta_1\} \cap \{\omega \mid \xi(\omega) \in \Delta_2\} = \\ &= \{\omega \mid \xi(\omega) \in \Delta_1 \wedge \xi(\omega) \in \Delta_2\} = \\ &= \{\omega \mid \xi(\omega) \in \Delta_1 \cap \Delta_2\} = \xi^{-1}(\Delta_1 \cap \Delta_2) \end{aligned}$$

Значит, имеем равенство

$$\xi^{-1}(\Delta_1) \cap \xi^{-1}(\Delta_2) = \xi^{-1}(\Delta_1 \cap \Delta_2)$$

Пользуясь методом математической индукции нетрудно показать, что для любого n выполняется

$$\xi^{-1}\left(\bigcap_{i=1}^n \Delta_i\right) = \bigcap_{i=1}^n \xi^{-1}(\Delta_i), \Delta_i \in \mathfrak{B}$$

Как устроена эта σ -алгебра? Каждому элементарному исходу отвечает одно и только одно значение случайной величины, а каждому значению случайной величины отвечает один и больше элементарных исходов. Допустим, есть некое $a \in \mathbb{R}$, которое является образом по крайней мере двух элементарных исходов ω_1 и ω_2

$$\xi(\omega_1) = \xi(\omega_2) = a$$

Теперь рассмотрим элемент Δ борелевской σ -алгебры \mathfrak{B} . Из вышесказанного следует, что, если число a принадлежит множеству Δ , то прообраз этого множества содержит элементы ω_1 и ω_2 , в противном случае оба элементарных исхода не входят в прообраз

$$\begin{aligned} a \in \Delta &\Rightarrow \xi^{-1}(\Delta) \ni \omega_1, \omega_2 \\ a \notin \Delta &\Rightarrow \xi^{-1}(\Delta) \not\ni \omega_1, \omega_2 \end{aligned}$$

То есть, множество \mathfrak{F}_ξ не будет различать элементы ω_1 и ω_2 . Это в свою очередь означает, что можно разбить \mathfrak{F}_ξ на уровни — непересекающиеся подмножества

Определение 2.2.2: Множество уровня

Множество уровня H_t — полный прообраз значения $t \in \mathbb{R}$ случайной величины ξ

$$H_t = \{\omega \mid \xi(\omega) = t\} = \xi^{-1}(t)$$

Замечание 2.2.3

Уровни H_i составляют разбиение множества элементарных исходов Ω .

1. Множества H_i не пересекаются

$$H_{t_1} \neq H_{t_2} \Leftrightarrow t_1 \neq t_2$$

2. Объединение всех H_i даёт множество элементарных исходов

$$\bigcup_{t \in \mathbb{R}} H_t = \bigcup_{t \in \mathbb{R}} \xi^{-1}(t) = \xi^{-1}(\mathbb{R}) = \Omega$$

Очень похоже на гипотезы из курса теории вероятностей с той лишь разницей, что уровней может быть бесконечное и даже континуальное количество, из чего также следует, что вероятность некоторых из них может быть нулевой.

2.3 Случайная величина, измеримая относительно σ -алгебры

В общем случае вероятностное пространство может быть разбито на континуальное количество множеств уровней (для σ -алгебры, порождённой непрерывной случайной величиной).

Начнём же с рассмотрения того случая, когда случайная величина ξ принимает n значений a_1, a_2, \dots, a_n

$$\xi : \Omega \rightarrow \{a_1, a_2, \dots, a_n\}$$

Это в свою очередь означает, что у нас есть n уровней

$$H_k = \{\omega \mid \xi(\omega) = a_k\}, k = \overline{1, n}$$

Нетрудно понять, что σ -алгебра $\sigma(\xi)$ содержит 2^n элементов

$$\sigma(\xi) = \left\{ \bigcup_{k=1}^n H_k^{\eta_k} \mid \eta_k = \overline{0, 1}, H_k^0 = \emptyset, H_k^1 = H_k \right\}$$

Нам нет смысла пользоваться лишь одной случайной величиной ξ . Нас интересует, как устроены случайные величины, которые измеримы относительно σ -алгебры $\sigma(\xi)$.

Возьмём \varkappa — случайная величина, измеримая относительно $\sigma(\xi)$. Это значит, что все прообразы случайной величины \varkappa должны лежать в σ -алгебре $\sigma(\xi)$

$$\{\omega \mid \varkappa(\omega) \leq c\} \in \sigma(\xi)$$

То есть, прообразы \varkappa выражаются через объединения уровней H_k

$$\{\omega \mid \varkappa(\omega) \leq c\} = \bigcup_{k=1}^n H_k^{\eta_k}$$

Введём обозначение

$$A(c) = \{\omega \mid \varkappa(\omega) \leq c\}$$

Очевидно, что при $c \rightarrow -\infty$ прообразом является пустое множество, а когда $c \rightarrow +\infty$, то прообразом является всё множество элементарных исходов

$$\begin{aligned}\{\omega \mid \varkappa(\omega) \leq -\infty\} &= \{\omega \mid \varkappa(\omega) \in \emptyset\} = \varkappa^{-1}(\emptyset) = \emptyset \\ \{\omega \mid \varkappa(\omega) \leq +\infty\} &= \{\omega \mid \varkappa(\omega) \in \mathbb{R}\} = \varkappa^{-1}(\mathbb{R}) = \Omega\end{aligned}$$

Также ясно, что, если имеются два элемента борелевского множества и один включён в другой, то полный прообраз первого элемента тоже будет включён в прообраз второго

$$\begin{aligned}\Delta_1, \Delta_2 \in \mathfrak{B}, \Delta_1 \subseteq \Delta_2 \\ \Rightarrow \varkappa^{-1}(\Delta_1) \subseteq \varkappa^{-1}(\Delta_1) \cup \varkappa^{-1}(\Delta_2) = \\ = \varkappa^{-1}(\Delta_1 \cup \Delta_2) = \varkappa^{-1}(\Delta_2)\end{aligned}$$

Ни у кого не возникает сомнений, что справедливо и такое утверждение

$$c_1, c_2 \in \mathbb{R}, c_1 \leq c_2 \Rightarrow A(c_1) \subseteq A(c_2)$$

Объединим и проанализируем вышеописанное:

1. Количество элементов в множестве $A(c)$ не уменьшается с ростом c

$$c_1 \leq c_2 \Rightarrow A(c_1) \subseteq A(c_2)$$

2. Множество $A(c)$ “разрастается” от пустого множества \emptyset до множества элементарных событий Ω с ростом c от $-\infty$ до $+\infty$

$$A(-\infty) = \emptyset, A(+\infty) = \Omega$$

3. Множество $A(c)$ растёт дискретными шагами. Это связано с тем, что уровни H_k в нашей σ -алгебре неделимы, а каждый её элемент должен состоять из объединений этих уровней и ничего другого.

Из этого всего делаем более конкретные выводы о том, как изменяется значение функции $A(c)$ с ростом параметра c . Должны быть опорные точки, на которых происходит “скачок” — точки, на которых к объединению добавляется ещё один или более уровней.

Поскольку имеется n уровней, то может быть не более n скачков: ведь самый “медленный” рост будет происходить, если добавлять по одному уровню на определённых константах, а нужно пройти всё от пустого множества \emptyset до множества элементарных исходов Ω .

Выделим m точек ($m \leq n$) $c_1 < c_2 < \dots < c_m$ на числовой прямой \mathbb{R} как значения случайной величины \varkappa

$$\varkappa : \Omega \rightarrow \{c_1, c_2, \dots, c_m\}$$

Посмотрим, как соотносятся между собой $A(c_i)$ и $A(c_{i-1})$, чтобы лучше понять природу скачков.

Сначала покажем, что $A(c_1)$ является прообразом c_1

$$\varkappa^{-1}(c_1) = \{\omega \mid \varkappa(\omega) = c_1\}$$

Поскольку случайная величина не принимает значений до c_1 , то множество $A(c_1 - 0) = \{\omega \mid \varkappa(\omega) < c_1\}$ пустое. Получаем то, что хотели

$$\begin{aligned}\varkappa^{-1}(c_1) &= \{\omega \mid \varkappa(\omega) = c_1\} \cup \emptyset = \\ &= \{\omega \mid \varkappa(\omega) = c_1\} \cup \{\omega \mid \varkappa(\omega) < c_1\} = \\ &= \{\omega \mid \varkappa(\omega) \leq c_1\} = A(c_1)\end{aligned}$$

Идём дальше. Обозначим $c_0 = -\infty$. Тогда в каждой точке $A(c_i)$, $i = \overline{1, m}$ происходит скачок на множество $\varkappa^{-1}(c_i)$, то есть

$$A(c_i) = A(c_{i-1}) \cup \varkappa^{-1}(c_i)$$

Так происходит, потому что имеет место равенство, которое выполняется из-за того, что функция имеет скачки лишь на параметрах c_i , а между ними не меняет значения

$$A(c_i) = A(c_{i+1} - 0)$$

В таком случае тождество очевидно

$$\begin{aligned}A(c_i) &= \{\omega \mid \varkappa(\omega) \leq c_i\} = \\ &= \{\omega \mid \varkappa(\omega) < c_i\} \cup \{\omega \mid \varkappa(\omega) = c_i\} = \\ &= A(c_{i-1} - 0) \cup \varkappa^{-1}(c_i) = A(c_{i-1}) \cup \varkappa^{-1}(c_i)\end{aligned}$$

Поскольку \varkappa — случайная величина, принимающая m значений, то её прообразы составляют разбиение пространства элементарных исходов Ω . А поскольку $A(c_{i-1})$ состоит из объединений этих прообразов, то оно не пересекается с $\varkappa^{-1}(c_i)$. То есть, мы знаем, как вычислять прообраз \varkappa

$$\begin{cases} A(c_{i-1}) \cap \varkappa^{-1}(c_i) = \emptyset \\ A(c_i) = A(c_{i-1}) \cup \varkappa^{-1}(c_i) \end{cases} \Rightarrow \varkappa^{-1}(c_i) = A(c_i) \setminus A(c_{i-1})$$

Значит, случайная величина \varkappa принимает значение c_i при выпадении любого элементарного исхода ω из множества $A(c_i) \setminus A(c_{i-1})$

$$\varkappa(\omega) = c_i, \omega \in A(c_i) \setminus A(c_{i-1}) \quad (2.2)$$

Запишем это в более удобном виде

$$\varkappa(\omega) = \sum_{i=1}^m c_i \cdot \mathbb{1}\{\omega \in A(c_i) \setminus A(c_{i-1})\}$$

Но эта сумма кажется уродливой из-за длинного индикатора и непонятного m . Попробуем разобраться, в чём же дело и как прийти к изначальной n и милым H_k .

Помним, что $A(c_i) \setminus A(c_{i-1})$ — объединение нескольких множеств уровня H_k .

Для любого t разность множеств $A(c_t) \setminus A(c_{t-1}) \neq \emptyset$ (когда это множество пустое, то индикатор просто не сработает и нечего считать) можно представить как объединение двух непересекающихся множеств, которые обозначим $H_1^t \in \mathfrak{F}$ и $H_2^t \in \mathfrak{F}$, причём H_1^t — множество уровня, а H_2^t —

произвольное множество из \mathfrak{F} (в том числе и пустое, если разность и есть множество уровня). Тогда t -ое слагаемое примет следующий вид

$$c_t \cdot \mathbb{1}\{\omega \in A(c_t) \setminus A(c_{t-1})\} = c_t \cdot \mathbb{1}\{\omega \in H_1^t \cup H_2^t\}$$

Поскольку множества H_1^t и H_2^t по условию не пересекаются, то можно разбить индикатор на сумму

$$\begin{aligned} c_t \cdot \mathbb{1}\{\omega \in H_1^t \cup H_2^t\} &= c_t \cdot (\mathbb{1}\{\omega \in H_1^t\} + \mathbb{1}\{\omega \in H_2^t\}) \\ &= c_t \cdot \mathbb{1}\{\omega \in H_1^t\} + c_t \cdot \mathbb{1}\{\omega \in H_2^t\} \end{aligned}$$

Если ввести две константы c_1^t и c_2^t , которые будут равны старой c_t , то равенство примет более симпатичный вид

$$c_t \cdot \mathbb{1}\{\omega \in H_1^t\} + c_t \cdot \mathbb{1}\{\omega \in H_2^t\} = c_1^t \cdot \mathbb{1}\{\omega \in H_1^t\} + c_2^t \cdot \mathbb{1}\{\omega \in H_2^t\}$$

Если же H_2^t не является пустым множеством \emptyset или множеством уровня H_k , то нужно повторить процедуру, разбив H_2^t на объединение двух непесекающихся множеств — на множество уровня и множество из \mathfrak{F} . В итоге (вследствие конечности множества \mathfrak{F}) индикатор разности $A(c_t) \setminus A(c_{t-1})$ будет разбита на сумму индикаторов множеств уровней.

Таким же образом можно поступить со всеми остальными индикаторами. В итоге получим n констант d_1, d_2, \dots, d_n вместо m чисел c_1, c_2, \dots, c_m .

Теперь сумма примет более приятный для глаз и понятный из контекста начала раздела вид

$$\begin{aligned} \varkappa(\omega) &= \sum_{i=1}^m c_i \cdot \mathbb{1}\{\omega \in A(c_i) \setminus A(c_{i-1})\} = \\ &= \sum_{i=1}^n d_i \cdot \mathbb{1}\{\omega \in H_i\} \end{aligned}$$

Видим, что теперь можно определить отображение из множества значений, принимаемых случайной величиной ξ , в множество значений, принимаемых случайной величиной \varkappa

$$f : \{a_1, a_2, \dots, a_n\} \rightarrow \{d_1, d_2, \dots, d_n\}$$

Попробуем показать, что \varkappa является функцией от ξ . Очевидно, что случайная величина ξ имеет такой же вид, что и \varkappa — сумма констант, умноженных на индикаторы, так как мы только что показали, что все функции, измеримые относительно σ -алгебры, порождённой случайной величиной ξ , выглядят именно так

$$f(\xi(\omega)) = f\left(\sum_{i=1}^n a_i \cdot \mathbb{1}\{\omega \in H_i\}\right)$$

Поскольку уровни H_i не пересекаются, то лишь одно слагаемое не будет равно нулю: ω может принадлежать лишь одному уровню. В таком случае запись принимает свой изначальный вид без суммы (2.2)

$$f(\xi(\omega)) = f(a_i), \omega \in H_i$$

Замечаем, что $f(a_i) = d_i$, а это и есть то значение, которое принимает случайная величина \varkappa на уровне H_i

$$f(\xi(\omega)) = f(a_i) = d_i = \varkappa(\omega), \omega \in H_i$$

Поскольку мы не привязывались к конкретным i и конкретным ω , то получаем желаемое равенство

$$\varkappa = f(\xi)$$

Отсюда делаем следующий вывод

Утверждение 2.3.1

Случайной величине \varkappa необходимо и достаточно быть функцией случайной величины ξ , чтобы быть измеримой относительно σ -алгебры, порождённой случайной величиной ξ .

2.4 Условное математическое ожидание

Имеется произвольная случайная величина η , интегрируемая с квадратом. Нужно найти случайную величину $\tilde{\eta}$ которая измерима в $\sigma(\xi)$ и ближайшая в среднем квадратическом к η .

2.4.1 Проекция вектора

Для наглядности начнём с геометрической интерпретации задачи. Если представить η как вектор в некоем пространстве \mathfrak{L} , а $\sigma(\xi)$ как подпространство пространства \mathfrak{L} , то $\tilde{\eta}$ будет ни что иное, как проекция случайной величины η на пространство $\sigma(\xi)$.

Отдохнём от случайных величин и вспомним геометрию.

Имеется точка x в пространстве L' . Мы ищем такую точку y в подпространстве $L \subset L'$, что расстояние между x и y минимальное. Значит, надо опустить перпендикуляр от y на L .

У нас есть e_1, e_2, \dots, e_n — ортонормированный базис в L , тогда y можно найти по формуле

$$y = \sum_{k=1}^n (x, e_k) \cdot e_k \quad (2.3)$$

Потому что $y \in L$ должен лежать в пространстве L по условию, а это значит, что он должен быть линейной комбинацией базисных векторов e_1, e_2, \dots, e_n и это очевидно выполняется

Также разностью $x - y$ должен быть вектор, перпендикулярный пространству L . То есть, скалярное произведение этой разности с любым вектором z из пространства L должно равняться нулю

$$(x - y) \perp L \Leftrightarrow \forall z \in L : (x - y, z) = 0$$

Вследствие линейности скалярного произведения можно переписать это условие иначе

$$\begin{cases} \forall z \in L : (x - y, z) = 0 \\ (a + b, c) = (a, c) + (b, c) \end{cases} \Rightarrow \forall z \in L : (x, z) = (y, z)$$

Покажем, что и это выполняется. z является линейной комбинацией базисных векторов. Запишем это

$$z = \sum_{k=1}^n \beta_k \cdot e_k$$

В таком случае скалярное произведение (x, z) будет таким

$$(x, z) = \sum_{k=1}^n \beta_k \cdot (x, e_k)$$

С произведением (y, x) придётся чуть-чуть повозиться

$$(y, x) = \left(\sum_{k=1}^n (x, e_k) \cdot e_k, \sum_{k=1}^n \beta_k \cdot e_k \right) = \sum_{k=1}^n (x, e_k) \cdot \beta_k$$

Как видим, суммы равны, а значит, проекция x на L найдена верно.

2.4.2 Проекция случайной величины

Возьмём L — множество всех случайных величин, которые измеримы относительно $\sigma(\xi)$.

$$L \ni \sum_{k=1}^n c_k \cdot \mathbb{1}_{H_k}, c_k \in \mathbb{R}$$

Но что же взять в качестве ортонормированного базиса? По внешнему виду элементов пространства L кажется, что это $\mathbb{1}_{H_k}$. В качестве скалярного произведения случайных величин возьмём математическое ожидание произведения.

Оказывается, H_k действительно ортогональны

$$k_1 \neq k_2 \Rightarrow H_{k_1} \cap H_{k_2} = \emptyset \Rightarrow \mathbb{M}[\mathbb{1}_{H_{k_1}} \cdot \mathbb{1}_{H_{k_2}}] = 0$$

Теперь нужно нормировать эти базисные вектора, а для этого их надо поделить на их нормы. В нашем пространстве норма порождена скалярным произведением, то есть

$$\|x\| = \sqrt{(x, x)} = \sqrt{\mathbb{M}[x \cdot x]} = \sqrt{\mathbb{M}[x^2]}, x \in L$$

Теперь у нас есть всё необходимое для того, чтобы представить ортонормированный базис. Начнём преобразования H_k

$$e_k = \frac{\mathbb{1}_{H_k}}{\sqrt{\mathbb{M}(\mathbb{1}_{H_k})^2}}$$

Поскольку индикатор может принимать лишь одно из двух значений 0 или 1, а их квадраты равны им самим, то в формуле квадрат тоже можно убрать

$$e_k = \frac{\mathbb{1}_{H_k}}{\sqrt{\mathbb{M} \mathbb{1}_{H_k}}}$$

Также помним, что математическое ожидание в знаменателе есть ни что иное, как вероятность события H_k , и теперь у нас есть красивый ортонормированный базис

$$e_k = \frac{\mathbb{1}_{H_k}}{\sqrt{\mathbb{P}(H_k)}} \quad (2.4)$$

Идём дальше, ищем проекцию. Вспомним снова пример с векторами (2.3)

$$y = \sum_{k=1}^n (x, e_k) \cdot e_k$$

Если заменить y на $\tilde{\eta}$, а x на η , то получаем следующую картину, имеющую непосредственное отношение к задаче

$$\tilde{\eta} = \sum_{k=1}^n (\eta, e_k) \cdot e_k$$

Осталось заменить e_k на то, что получили выше (2.4)

$$\tilde{\eta} = \sum_{k=1}^n \left(\eta, \frac{\mathbb{1}_{H_k}}{\sqrt{\mathbb{P}(H_k)}} \right) \cdot \frac{\mathbb{1}_{H_k}}{\sqrt{\mathbb{P}(H_k)}}$$

Заменяем скалярное произведение на математическое ожидание произведения и получаем то, с чем можно дальше работать, не отвлекаясь на геометрию

$$\tilde{\eta} = \sum_{k=1}^n \mathbb{M} \left(\eta \cdot \frac{\mathbb{1}_{H_k}}{\sqrt{\mathbb{P}(H_k)}} \right) \cdot \frac{\mathbb{1}_{H_k}}{\sqrt{\mathbb{P}(H_k)}}$$

Поскольку вероятность $\mathbb{P}(H_k)$ — константа, то её можно вынести за математическое ожидание

$$\tilde{\eta} = \sum_{k=1}^n \frac{\mathbb{M} [\eta \cdot \mathbb{1}_{H_k}]}{\sqrt{\mathbb{P}(H_k)}} \cdot \frac{\mathbb{1}_{H_k}}{\sqrt{\mathbb{P}(H_k)}}$$

При умножении знаменателей получаем вероятность события H_k . Теперь у нас есть красивая формула для проекции случайной величины

$$\tilde{\eta} = \sum_{k=1}^n \frac{\mathbb{M} [\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)} \cdot \mathbb{1}_{H_k} \quad (2.5)$$

На что стоит обратить внимание в этой формуле:

1. $\tilde{\eta}$ — **случайная величина**, так как индикатор вне математического ожидания никуда не девается и результат суммы будет зависеть от произошедшего ω , а точнее от того, какому уровню H_k оно принадлежит

2. Когда ω принадлежит H_k , то результатом суммы будет среднее значение случайной величины η на событии H_k

Если с первым пунктом всё очевидно, то небольшое пояснение ко второму не помешает.

Нужно показать, что k -я “координата” случайной величины $\tilde{\eta}$ действительно даёт среднее значение случайной величины η на событии H_k

$$\frac{\mathbb{M}[\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)}$$

Начнём с определения математического ожидания

$$\begin{aligned} \mathbb{M}[\eta \cdot \mathbb{1}_{H_k}] &= \int_{\Omega} \eta(\omega) \cdot \mathbb{1}_{H_k} \mathbb{P}(d\omega) = \\ &= \int_{H_k} \eta(\omega) \mathbb{P}(d\omega) + \int_{\Omega \setminus H_k} 0 \mathbb{P}(d\omega) \end{aligned} \quad (2.6)$$

Видим математическое ожидание случайной величины, которая гарантированно принимает нулевое значение на множестве $\Omega \setminus H_k$, что в свою очередь искажает желаемую картину и притягивает результат к нулю с силой, которая пропорциональна $\mathbb{P}(\Omega \setminus H_k)$. То есть, “вес” каждого ненулевого значения случайной величины уменьшился.

Почему так происходит? Потому что вероятность события H_k в общем случае не равна единице. Если ввести новую меру $\mathbb{P}_k(A) = \frac{\mathbb{P}(A)}{\mathbb{P}(H_k)}$, то наступит гармония, а вероятность $\mathbb{P}_k(H_k)$ будет равна единице.

Из контекста понятно, что эта мера будет использоваться лишь в интеграле по событию H_k , поэтому её значение будет колебаться в пределах $[0; 1]$, но строгости ради введём небольшую поправку (и увидим, что не напрасно)

$$\mathbb{P}_k(A) = \frac{\mathbb{P}(A \cap H_k)}{\mathbb{P}(H_k)}$$

Видим условную вероятность, а это значит, что мы на правильном пути! Логично, что в поисках условного математического ожидания должна была встретиться условная вероятность

$$\mathbb{P}_k(A) = \frac{\mathbb{P}(A \cap H_k)}{\mathbb{P}(H_k)} = \mathbb{P}(A \mid H_k)$$

Теперь математическое ожидание (2.6) принимает несколько иной вид

$$\mathbb{M}[\eta \cdot \mathbb{1}_{H_k}] = \mathbb{P}(H_k) \cdot \int_{H_k} \eta(\omega) \mathbb{P}(d\omega \mid H_k)$$

Тут уже уровень H_k играет роль целого множества элементарных исходов, его мера $\mathbb{P}(H_k \mid H_k)$ равна единице, а мы получаем действительно

среднее значение случайной величины η на множестве H_k , умноженное на вероятность $\mathbb{P}(H_k)$. Значит, осталось лишь поделить обе части на $\mathbb{P}(H_k)$

$$\frac{\mathbb{M}[\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)} = \int_{H_k} \eta(\omega) \mathbb{P}(d\omega | H_k)$$

Определение 2.4.1: Условное математическое ожидание случайной величины относительно случайного события

Условное математическое ожидание случайной величины ξ относительно события A [2, стр. 68] обозначается $\mathbb{M}[\xi | A]$ и считается по формуле

$$\mathbb{M}[\xi | A] = \frac{\mathbb{M}[\xi \cdot \mathbb{1}_A]}{\mathbb{P}(A)} = \int_A \xi(\omega) \mathbb{P}(d\omega | A)$$

Пользуясь только что введённым обозначением, можно более красиво переписать формулу (2.5) для получения проекции случайной величины η на σ -алгебру, порождённую уровнями H_1, H_2, \dots, H_n

$$\tilde{\eta} = \sum_{k=1}^n \mathbb{M}[\eta | H_k] \cdot \mathbb{1}_{H_k}$$

Забегая наперёд, введём определение частного случая условного математического ожидания случайной величины относительно σ -алгебры, чтобы обратить внимание на этот важный момент.

Определение 2.4.2: Условное математическое ожидание случайной величины относительно сигма-алгебры, порождённой случайной величиной, принимающей конечное количество значений

Есть σ -алгебра \mathfrak{F}_1 , разбитая на n уровней H_1, H_2, \dots, H_n . Тогда условное математическое ожидание случайной величины η относительно этой σ -алгебры — **случайная величина**, которая обозначается $\mathbb{M}[\eta | \mathfrak{F}_1]$ и вычисляется по формуле

$$\mathbb{M}[\eta | \mathfrak{F}_1] = \sum_{k=1}^n \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)} \cdot \mathbb{1}_{H_k}$$

Замечание 2.4.3

У нас есть определения условного математического ожидания относительно σ -алгебры \mathfrak{F} и относительно случайного события A . Из контекста будет ясно, какое именно определение используется, поэтому путаницы возникнуть не должно.

Например, последнее определение может выглядеть немного стран-

но

$$\mathbb{M}[\eta \mid \mathfrak{F}_1] = \sum_{k=1}^n \mathbb{M}[\eta \mid H_k] \cdot \mathbb{1}_{H_k}$$

Зато при более детальном рассмотрении из самой записи очевиден её смысл: условное математическое ожидание относительно σ -алгебры — вектор, для получения которого нужно умножить проекции на базисные векторы. Ведь $\mathbb{M}[\eta \mid H_k]$ — ни что иное, как проекция вектора (случайной величины) η на ось (уровень) H_k , также эта величина является скаляром, как и проекция вектора на ось.

Лемма 2.4.4: Равенство скалярных произведений для конечной сигма-алгебры

Для случайной величины η и её проекции $\tilde{\eta}$ на σ -алгебру \mathfrak{F}_ξ , порождённую случайной величиной ξ , принимающей конечное количество значений, выполняется равенство скалярных произведений

$$\forall A \in \mathfrak{F}_\xi : \mathbb{M}[\tilde{\eta} \cdot \mathbb{1}_A] = \mathbb{M}[\eta \cdot \mathbb{1}_A] \quad (2.7)$$

Доказательство. Для начала распишем $\tilde{\eta}$ по определению

$$\mathbb{M}[\tilde{\eta} \cdot \mathbb{1}_A] = \mathbb{M}\left(\sum_{k=1}^n \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)} \cdot \mathbb{1}_{H_k} \cdot \mathbb{1}_A\right)$$

Произведение индикаторов $\mathbb{1}_{H_k}$ и $\mathbb{1}_A$ — индикатор пересечения $\mathbb{1}_{H_k \cap A}$. Воспользуемся линейностью математического ожидания, не забывая, что дробь в каждом слагаемом — константа и выносится за знак математического ожидания

$$\mathbb{M}\left(\sum_{k=1}^n \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)} \cdot \mathbb{1}_{H_k} \cdot \mathbb{1}_A\right) = \sum_{k=1}^n \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)} \cdot \mathbb{M}[\mathbb{1}_{H_k \cap A}]$$

Помним, что математическое ожидание индикатора — вероятность

$$\sum_{k=1}^n \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)} \cdot \mathbb{M}[\mathbb{1}_{H_k \cap A}] = \sum_{k=1}^n \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)} \cdot \mathbb{P}(H_k \cap A)$$

Замечаем условную вероятность

$$\begin{aligned} \sum_{k=1}^n \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)} \cdot \mathbb{P}(H_k \cap A) &= \sum_{k=1}^n \mathbb{M}[\eta \cdot \mathbb{1}_{H_k}] \cdot \frac{\mathbb{P}(H_k \cap A)}{\mathbb{P}(H_k)} = \\ &= \sum_{k=1}^n \mathbb{M}[\eta \cdot \mathbb{1}_{H_k}] \cdot \mathbb{P}(A \mid H_k) \end{aligned}$$

Поскольку A принадлежит множеству случайных событий \mathfrak{F}_ξ , то условная вероятность $\mathbb{P}(A \mid H_k)$ равна либо нулю, либо единице, поскольку A

либо включает в себя уровень H_k , либо не пересекается с ним. То есть, получился индикатор $\mathbb{1}(H_k \subseteq A)$. А этот индикатор говорит о том, что теперь надо суммировать лишь по тем уровням, которые являются частью события A , а дальше можно смело воспользоваться линейностью математического ожидания

$$\begin{aligned} \sum_{k=1}^n \mathbb{M} [\eta \cdot \mathbb{1}_{H_k}] \cdot \mathbb{P}(A \mid H_k) &= \sum_{k=1}^n \mathbb{M} [\eta \cdot \mathbb{1}_{H_k}] \cdot \mathbb{1}(H_k \subseteq A) = \\ &= \sum_{H_k \subseteq A} \mathbb{M} [\eta \cdot \mathbb{1}_{H_k}] = \mathbb{M} \left[\sum_{H_k \subseteq A} \eta \cdot \mathbb{1}_{H_k} \right] \end{aligned}$$

Далее мы имеем полное математическое и моральное право вынести η за знак суммы. Если с математикой всё очевидно (работает закон дистрибутивности), то напомним о морально-этической стороне дела: нам нужно, пройтись по всем возможным индикаторам $\mathbb{1}_{H_k}$, из которых лишь один работает (будет равен единице, а не нулю), поэтому сумма нужна лишь для того, чтобы не писать в конце каждой строчки “для тех ω , что входят в H_k ” (помним, что случайная величина и индикатор — функции от элементарного события ω)

$$\mathbb{M} \left[\sum_{H_k \subseteq A} \eta \cdot \mathbb{1}_{H_k} \right] = \mathbb{M} \left[\eta(\omega) \cdot \sum_{H_k \subseteq A} \mathbb{1}_{H_k}(\omega) \right]$$

Сумма индикаторов непересекающихся событий — индикатор их объединения, которое является множеством A . Не забываем, что оно может состоять из объединений уровней и только из них (или же быть пустым)

$$\mathbb{M} \left[\eta \cdot \sum_{H_k \subseteq A} \mathbb{1}_{H_k} \right] = \mathbb{M} [\eta \cdot \mathbb{1}_A]$$

Значит, равенство (2.7) выполняется. \square

Замечание 2.4.5

В связи с выполнением равенства скалярных произведений можем сделать вывод, что математическое ожидание случайной величины и её проекции тоже равны. Это нетрудно показать, установив A равным всему множеству элементарных исходов (индикатор в таком случае станет просто тождественной единицей)

$$\mathbb{M}\eta = \mathbb{M} [\eta \cdot \mathbb{1}_\Omega] = \mathbb{M} [\tilde{\eta} \cdot \mathbb{1}_\Omega] = \mathbb{M}\tilde{\eta}$$

2.4.3 Условное математическое ожидание

Введём же общее определение для условного математического ожидания случайной величины относительно σ -алгебры

Определение 2.4.6: Условное математическое ожидание случайной величины относительно сигма-алгебры

Условным математическим ожиданием случайной величины η относительно σ -алгебры \mathfrak{F}_1 называется такая случайная величина $\tilde{\eta}$, что

1. Случайная величина $\tilde{\eta}$ измерима относительно σ -алгебры \mathfrak{F}_1
2. Выполняется равенство скалярных произведений

$$\forall A \in \mathfrak{F}_1 : M[\tilde{\eta} \cdot \mathbb{1}_A] = M[\eta \cdot \mathbb{1}_A]$$

Обозначение $\tilde{\eta} = M[\eta | \mathfrak{F}_1]$

Замечание 2.4.7

Условное математическое ожидание случайной величины η относительно σ -алгебры, порождённой случайной величиной ξ , будем обозначать $M[\eta | \sigma(\xi)]$, а более кратко $M[\eta | \xi]$.

То есть, имеем три эквивалентных записи

$$M[\eta | \mathfrak{F}_\xi] = M[\eta | \sigma(\xi)] = M[\eta | \xi]$$

Немного остановимся на примере, чтобы понять, что у нас есть на данный момент

Пример 2.4.8

У нас есть две дискретные случайные величины ξ и η с совместным дискретным распределением

$$\mathbb{P}\{\xi = a_i, \eta = b_j\} = p_{ij}$$

Очевидно, что числа p_{ij} обладают некоторым свойством

$$p_{ij} \geq 0, \quad \sum_{i,j=1}^{\infty} p_{ij} = 1, \quad \mathbb{P}\{\eta = b_j\} = \sum_{i=1}^{\infty} p_{ij}$$

Посчитаем условное математическое ожидание согласно формуле из определения (2.4.2)

$$M[\xi | \sigma(\eta)] = \sum_{k=1}^n \frac{M[\eta \cdot \mathbb{1}_{H_k}]}{\mathbb{P}(H_k)} \cdot \mathbb{1}_{H_k}$$

Для этого выясним, чему равно математическое ожидание ξ при

определённом значении η по формуле из определения (2.4.1)

$$\mathbb{M}[\xi \mid \eta = b_j] = \frac{\mathbb{M}[\xi \cdot \mathbb{1}_{\eta=b_j}]}{\mathbb{P}\{\eta = b_j\}} = \frac{\sum_{i=1}^{\infty} a_i \cdot p_{ij}}{\sum_{i=1}^{\infty} p_{ij}}$$

Попробуем обобщить определение условного математического ожидания, чтобы обладать универсальной формулой, из которой можно делать какие-то выводы. Начнём с того, что у нас уже есть

$$\mathbb{M}[\eta \mid \mathfrak{F}_\xi] = \sum_{k=1}^n \mathbb{M}[\eta \mid H_k] \cdot \mathbb{1}_{H_k}$$

Множество уровня H_k — прообраз одного из значений случайной величины ξ , которой порождена σ -алгебра \mathfrak{F}_ξ . Если назвать эти значения a_1, a_2, \dots, a_n , то запись примет следующий вид

$$\mathbb{M}[\eta \mid \sigma(\xi)] = \sum_{k=1}^n \mathbb{M}[\eta \mid \xi^{-1}(a_k)] \cdot \mathbb{1}_{\{\xi^{-1}(a_k)\}} \quad (2.8)$$

Вспомним альтернативные записи прообраза

$$\xi^{-1}(a_k) = \{\omega \mid \xi(\omega) = a_k\} = \{\xi = a_k\}$$

И перепишем формулу (2.8)

$$\mathbb{M}[\eta \mid \sigma(\xi)] = \sum_{k=1}^n \mathbb{M}[\eta \mid \xi = a_k] \cdot \mathbb{1}_{\xi=a_k}$$

Теперь введём функцию $\varphi^\eta(x) = \mathbb{M}[\eta \mid \xi = x]$ и условное математическое ожидание примет следующий вид

$$\mathbb{M}[\eta \mid \xi] = \sum_{k=1}^n \varphi^\eta(a_k) \cdot \mathbb{1}_{\xi=a_k}$$

Вновь вспоминаем роль суммы и индикаторов и видим, что условное математическое ожидание в нашей формуле принимает значение $\varphi^\eta(x)$ в зависимости от того, какое значение приняла случайная величина $\xi(\omega)$. То есть, можно переписать равенство следующим образом

$$\mathbb{M}[\eta \mid \xi] = \varphi^\eta(a_k) : \xi(\omega) = a_k$$

То есть, можно просто подставить значение случайной величины ξ в качестве аргумента функции φ^η и получим условное математическое ожидание

$$\mathbb{M}[\eta \mid \xi] = \varphi^\eta(\xi)$$

Остановимся ещё немного на функции φ^η . Она является случайной величиной, поэтому перепишем равенство следующим образом

$$\varphi^\eta(\xi)(\omega) = \mathbb{M}[\eta \mid \xi](\omega)$$

Тогда будет корректна следующая запись

$$\varphi^\eta(\xi)(\omega) = \mathbb{M}[\eta \mid \xi = t] \Big|_{t=\xi(\omega)}$$

Не путаем случайную величину $\xi(\omega)$ саму по себе со случайной величиной в случайном событии

$$H_t = \{\xi = t\} = \{\tilde{\omega} \mid \xi(\tilde{\omega}) = t\}$$

Для удобства вернёмся к обозначению H_t

$$\varphi^\eta(\xi)(\omega) = \mathbb{M}[\eta \mid H_t] \Big|_{t=\xi(\omega)} = \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{H_t}]}{\mathbb{P}(H_t)} \Big|_{t=\xi(\omega)}$$

Покажем, что такая формула вычисления условного математического ожидания подходит для общего случая.*

Лемма 2.4.9: Равенство скалярных произведений в общем случае

В общем случае случайная величина $\varphi^\eta(\xi)$ является условным математическим ожиданием случайной величины η относительно σ -алгебры, порождённой случайной величиной ξ

$$\mathbb{M}[\eta \mid \sigma(\xi)] = \varphi^\eta(\xi)$$

Доказательство. Нужно доказать то, что выполняются оба свойства условного математического ожидания.

То, что $\varphi^\eta(\xi)$ измерима относительно $\sigma(\xi)$, очевидно из определения: $\varphi^\eta(\xi)$ является функцией случайной величины ξ , а это и есть измеримость. Далее придётся немного повозиться.

$$\forall A \in \sigma(\xi) : \mathbb{M}[\varphi^\eta(\xi) \cdot \mathbb{1}_A] = \mathbb{M}[\eta \cdot \mathbb{1}_A]$$

Следуем определению. Пока что ничего очевидного нет кроме надежды на то, что была выведена достаточно общая формула, которая должна работать

$$\mathbb{M}[\varphi^\eta(\xi) \cdot \mathbb{1}_A] = \int_{\Omega} \varphi^\eta(\xi) \cdot \mathbb{1}_A d\mathbb{P}$$

Применим индикатор и будем интегрировать не по всему множеству элементарных исходов, а лишь по событию A , а также в явном виде покажем элементарный исход ω , так как сейчас с ним надо будет поработать основательно

$$\int_{\Omega} \varphi^\eta(\xi) \cdot \mathbb{1}_A d\mathbb{P} = \int_A \varphi^\eta(\xi(\omega)) \mathbb{P}(d\omega) \quad (2.9)$$

*Так как формула была выведена из условного математического ожидания относительно σ -алгебры, порождённой случайной величиной, принимающей конечное количество значений, то справедливость формулы для этого случая доказывать уже нет нужды

Теперь нужно немного остановиться и подумать, что же делать дальше. Немного выше оказалось, что сама по себе запись $\varphi^\eta(\xi)$ не даёт ничего полезного. Копнём немного глубже и посмотрим на то, что есть у нас. Значение случайной величины использовалось лишь для восстановления случайного события, которому принадлежит произошедший элементарный исход ω^\dagger . То есть, мы знали, чему равна случайная величина, но не знали, какое именно событие произошло, зато могли определить, какому уровню принадлежит произошедшее событие. Тут же у нас есть интеграл и мы проходим по каждому мельчайшему событию $d\omega$. Вспомним, чему равна $\varphi^\eta(x)$

$$\varphi^\eta(x) = \mathbb{M}[\eta \mid \xi = x]$$

А теперь распишем условное математическое ожидание

$$\varphi^\eta(x) = \mathbb{M}[\eta \mid \xi = x] = \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{\{\xi=x\}}]}{\mathbb{P}\{\xi = x\}}$$

В общем случае для непрерывных случайных величин такая запись не имеет смысла, но мы как раз рассматриваем очень маленькие значения, а усложнять нет желания. Поэтому просто подставляем получившееся выражение в интеграл (2.9)

$$\int_A \varphi^\eta(\xi(\omega)) \mathbb{P}(d\omega) = \int_A \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{\{\xi=x\}}]}{\mathbb{P}\{\xi = x\}} \mathbb{P}(d\omega) \quad (2.10)$$

Дальше происходит магия, которую можно трактовать по-разному

Формулировка 1: Воспользовавшись вышесказанным, заменим событие $\{\xi = x\}$ на $d\omega$ и продолжим колдовать

$$\int_A \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{\{\xi=x\}}]}{\mathbb{P}\{\xi = x\}} \mathbb{P}(d\omega) = \int_A \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{d\omega}]}{\mathbb{P}(d\omega)} \mathbb{P}(d\omega)$$

Вероятности сокращаются, хоть это и немного смущает, а $d\omega$ находится в индикаторе, что ещё больше нагнетает обстановку. Учтём внесённые изменения и перепишем математическое ожидание через интеграл

$$\int_A \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{d\omega}]}{\mathbb{P}(d\omega)} \mathbb{P}(d\omega) = \int_A \int_\Omega \eta \cdot \mathbb{1}_{d\omega} \cdot \mathbb{P}(d\tilde{\omega})$$

Не путаемся: $d\omega$ принадлежит внешнему интегралу, а $d\tilde{\omega}$ внутреннему. Индикатор упрощает нашу задачу, сужая пределы интегрирования внутреннего интеграла до маленького события $d\omega$

$$\int_A \int_\Omega \eta \cdot \mathbb{1}_{d\omega} \cdot \mathbb{P}(d\tilde{\omega}) = \int_A \int_{d\omega} \eta(\tilde{\omega}) \mathbb{P}(d\tilde{\omega})$$

[†]Ведь именно по значению случайной величины мы и находили уровни, элементарные исходы которых для нас неразличимы внутри одного множества уровня

$$H_t = \xi^{-1}(a_t) = \{\omega \mid \xi(\omega) = a_t\}$$

Поскольку событие $d\omega$ и без того маленькое, дробить его на более мизерные $d\tilde{\omega}$ смысла нет, а это значит, что внутренний интеграл просто уничтожается и остаётся произведение случайной величины η на вероятность события $d\omega$

$$\int_{d\omega} \eta(\tilde{\omega}) \mathbb{P}(d\tilde{\omega}) = \eta(\omega) \cdot \mathbb{P}(d\omega)$$

Формулировка 2: Если посмотреть на исходный двойной интеграл, то можно увидеть условное математическое ожидание η относительно события $\{\xi = x\} = d\omega$

$$\int_A \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{\{\xi=x\}}]}{\mathbb{P}\{\xi=x\}} \mathbb{P}(d\omega) = \int_A \mathbb{M}[\eta \mid d\omega] \mathbb{P}(d\omega)$$

Если определить $d\omega$ как случайное событие, на котором случайная величина η принимает одно и то же значение почти всюду, то математическое ожидание равно значению η при появлении почти любого события из $d\omega^\ddagger$ (если значение на промежутке $d\omega$ — константа, то очевидно, что среднее значение будет равно ей же).

$$\int_A \mathbb{M}[\eta \mid d\omega] \mathbb{P}(d\omega) = \int_A \eta \mathbb{P}(d\omega)$$

С этим моментом разобрались, вернёмся же к нашему двойному интегралу (2.10). Получаем такой вот результат

$$\int_A \frac{\mathbb{M}[\eta \cdot \mathbb{1}_{\{\xi=x\}}]}{\mathbb{P}\{\xi=x\}} \mathbb{P}(d\omega) = \int_A \eta \mathbb{P}(d\omega)$$

Но ведь это и есть искомое математическое ожидание! Значит, свойство доказано, формула верна

$$\int_A \eta \mathbb{P}(d\omega) = \int_{\Omega} \eta \cdot \mathbb{1}_A \cdot \mathbb{P}(d\omega) = \mathbb{M}[\eta \cdot \mathbb{1}_A]$$

□

Теперь вернёмся к менее абстрактным вещам и посмотрим, как выглядит условное математическое ожидание, когда случайные величины ξ и η имеют совместную плотность распределения

$$\mathbb{P}\{(\xi, \eta) \in \Delta\} = \iint_{\Delta} p(x, y) \, dx \, dy$$

[‡]Нам достаточно постоянства значения $\xi(\omega)$ **почти всюду** на событии $d\omega$, так как интеграл Лебега простой функции (функции, что принимает конечное число значений [3, стр. 53]) — сумма значений функции, умноженных на меры соответствующих им прообразов [3, стр. 69]; в противном случае результатом будет наибольшее значение из интегралов Лебега всех простых функций, не превышающих данную в каждой точке. А это значит, что, если и будут отклонения от основного значения функции ξ на событии $d\omega$, то они будут уничтожаться мерой своих прообразов, равными нулю (в связи с тем, что функция $\xi(\omega)$ равна одному и тому же значению почти всюду на ω)

В таком случае компонента ξ имеет плотность r

$$r(x) = \int_{\mathbb{R}} p(x, y) dy$$

Компонента η имеет плотность q

$$q(y) = \int_{\mathbb{R}} p(x, y) dx$$

Уточним определение функции $\varphi^\eta(x)$ для данного случая. Вот первоначальный вариант

$$\varphi^\eta(x) = M[\eta \mid \xi = x] = \frac{M[\eta \cdot \mathbb{1}(\xi = x)]}{\mathbb{P}\{\xi = x\}}$$

В данном (непрерывном) случае вероятность события $\mathbb{P}\{\xi = x\}$ является плотностью случайной величины ξ в точке x

$$\mathbb{P}\{\xi = x\} = r(x)$$

Математическое ожидание случайной величины η , умноженной на индикатор $\mathbb{1}(\xi = x)$, есть ни что иное как математическое ожидание η при фиксированном $\xi = x$

$$M[\eta \cdot \mathbb{1}(\xi = x)] = \int_{\mathbb{R}} y \cdot p(x, y) dy$$

Теперь у нас есть конкретная формула для $\varphi^\eta(x)$ для случая непрерывных случайных величин с общей плотностью распределения

$$\varphi^\eta(x) = \frac{\int_{\mathbb{R}} y \cdot p(x, y) dy}{r(x)} = \frac{\int_{\mathbb{R}} y \cdot p(x, y) dy}{\int_{\mathbb{R}} p(x, y) dy} \quad (2.11)$$

Докажем снова, что $\varphi^\eta(\xi)$ является условным математическим ожиданием случайной величины η относительно σ -алгебры, порождённой случайной величиной ξ . Чтобы не было скучно, будем доказывать несколько иначе, чем ранее.

Лемма 2.4.10: Равенство скалярных произведений условного математического ожидания случайных величин с совместной плотностью

Пусть имеются две случайные величины (ξ, η) с совместной плотностью $p(x, y)$. Тогда функция

$$\varphi^\eta(\xi) = \frac{\int_{\mathbb{R}} y \cdot p(x, y) dy}{\int_{\mathbb{R}} p(x, y) dy} \Bigg|_{x=\xi}$$

Является условным математическим ожиданием $M[\eta \mid \xi]$

Доказательство. Первое свойство снова очевидно, поэтому надо доказать

$$\forall A \in \sigma(\xi) : M[\varphi^\eta(\xi) \cdot \mathbb{1}_A] = M[\eta \cdot \mathbb{1}_A] \quad (2.12)$$

У нас есть совместная плотность и мы хотим посчитать математическое ожидание, пользуясь именно ею. Для этого превратим индикатор $\mathbb{1}(\omega \in A)$ в функцию случайной величины ξ . Поскольку любое событие A принадлежит $\sigma(\xi)$, то оно представимо в виде $\xi^{-1}(\Delta)$, $\Delta \in \mathfrak{B}$. Перепишем индикатор следующим образом: $\mathbb{1}(\omega \in A) = \mathbb{1}(\xi \in \Delta)$. И вот теперь мы готовы к тому, чтобы записать определение математического ожидания

$$M[\varphi^\eta(\xi) \cdot \mathbb{1}_A] = \int_{\mathbb{R}} \int_{\mathbb{R}} \varphi^\eta(x) \cdot \mathbb{1}(x \in \Delta) \cdot p(x, y) \, dx \, dy$$

От y зависит лишь совместная плотность, а интеграл от неё по всей оси y является плотностью распределения ξ . То есть, интеграл по y уходит, а вместо $p(x, y)$ появляется $r(x)$. Также учтём индикатор и сузим область интегрирования с \mathbb{R} до Δ

$$\int_{\mathbb{R}} \int_{\mathbb{R}} \varphi^\eta(x) \cdot \mathbb{1}(x \in \Delta) \cdot p(x, y) \, dx \, dy = \int_{\Delta} \varphi^\eta(x) \cdot r(x) \, dx$$

Дальше распишем функцию φ^η , пользуясь формулой (2.11)

$$\int_{\Delta} \varphi^\eta(x) \cdot r(x) \, dx = \int_{\Delta} \left(\frac{\int_{\mathbb{R}} y \cdot p(x, y) \, dy}{r(x)} \cdot r(x) \right) dx$$

Сократим одинаковые плотности и получим интересный двойной интеграл

$$\int_{\Delta} \left(\frac{\int_{\mathbb{R}} y \cdot p(x, y) \, dy}{r(x)} \cdot r(x) \right) dx = \int_{\Delta} \int_{\mathbb{R}} y \cdot p(x, y) \, dy \, dx$$

Вернём индикатор обратно в интеграл

$$\int_{\Delta} \int_{\mathbb{R}} y \cdot p(x, y) \cdot dy \, dx = \int_{\mathbb{R}} \int_{\mathbb{R}} y \cdot \mathbb{1}(x \in \Delta) \cdot p(x, y) \, dy \, dx$$

Видим, что это и есть то математическое ожидание, которое нам нужно

$$\int_{\mathbb{R}} \int_{\mathbb{R}} y \cdot \mathbb{1}(x \in \Delta) \cdot p(x, y) \, dy \, dx = M[\eta \cdot \mathbb{1}_{\xi \in \Delta}] = M[\eta \cdot \mathbb{1}_A]$$

Это значит, что тождество доказано и условное математическое ожидание для случайных величин с совместной плотностью считается с помощью

$$\varphi^\eta(x) = \frac{\int_{\mathbb{R}} y \cdot p(x, y) \, dy}{\int_{\mathbb{R}} p(x, y) \, dy}$$

По формуле

$$M[\eta \mid \xi] = \varphi^\eta(\xi) = \varphi^\eta(x)|_{x=\xi}$$

□

Теорема 2.4.11: Существование условного математического ожидания

Условное математическое ожидание существует всегда и единственное почти наверное

Доказательство. [1, стр. 142]

□

2.4.4 Свойства условного математического ожидания

Были даны определения условного математического ожидания для разных случаев, теперь настало время привести основные свойства, которые позволят облегчить процедуру вычисления.[§]

I Формула полной вероятности [1, стр. 144]

$$MM[\eta \mid \mathfrak{F}_1] = M\eta$$

II Условное математическое ожидание неотрицательной случайной величины неотрицательно почти наверное

$$\eta \geq 0 \Rightarrow M[\eta \mid \mathfrak{F}_1] \geq 0$$

III Неравенство Йенсена. Если функция φ выпуклая вниз, то

$$\varphi(M[\eta \mid \mathfrak{F}_1]) \leq M[\varphi(\eta) \mid \mathfrak{F}_1]$$

IV Теорема о трёх перпендикулярах

$$\mathfrak{F}_2 \subset \mathfrak{F}_1 \Rightarrow M[M(\eta \mid \mathfrak{F}_1) \mid \mathfrak{F}_2] = M[\eta \mid \mathfrak{F}_2]$$

V Если случайная величина η измерима относительно σ -алгебры \mathfrak{F}_1 , то её условное математическое ожидание равно ей самой

$$M[\eta \mid \mathfrak{F}_1] = \eta$$

VI Если случайная величина η измерима относительно \mathfrak{F}_1 , то для любой случайной величины ξ

$$M[\eta \cdot \xi \mid \mathfrak{F}_1] = \eta \cdot M[\xi \mid \mathfrak{F}_1]$$

VII Если η не зависит от \mathfrak{F}_1 , то её условное математическое ожидание равно простому математическому ожиданию

$$\forall \Delta \in \mathfrak{B}, A \in \mathfrak{F}_1 : \mathbb{P}(\{\eta \in \Delta\} \mid A) = \{\eta \in \Delta\} \Rightarrow M[\eta \mid \mathfrak{F}_1] = M\eta$$

[§]Также со свойствами и их доказательствами можно ознакомиться в книгах Ширяева [4, стр. 270] и Боровкова [1, стр. 143]

VIII Условное математическое ожидание линейно

$$\forall a, b \in \mathbb{R} : M[a \cdot \xi + b \cdot \eta \mid \mathfrak{F}_1] = M[a \cdot \xi \mid \mathfrak{F}_1] + M[b \cdot \eta \mid \mathfrak{F}_1]$$

IX Сохраняется теорема Лебега о возможности предельного перехода под знаком условного математического ожидания [5, стр. 302]. В книге Ширяева это называется теоремой о сходимости под знаком условных ожиданий [4, стр. 272]

$$|\xi_n| \leq \eta, \quad M\eta < \infty, \quad \xi_n \xrightarrow[n \rightarrow \infty]{a.s.} \xi \Rightarrow M[\xi_n \mid \mathfrak{F}_1] \xrightarrow[n \rightarrow \infty]{a.s.} M[\xi \mid \mathfrak{F}_1]$$

Пара полезных частных случаев неравенства Йенсена (III свойство)

$$\begin{aligned} \varphi(x) = |x| : \quad M[\eta \mid \mathfrak{F}_1] &\leq M[|\eta| \mid \mathfrak{F}_1] \\ \varphi(x) = x^2 : \quad (M[\eta \mid \mathfrak{F}_1])^2 &\leq M[\eta^2 \mid \mathfrak{F}_1] \end{aligned}$$

2.4.5 Условное математическое ожидание функции произвольной случайной величины

Чем вызвала интерес эта тема? Допустим, у нас есть x_1, \dots, x_n — выборка с функцией правдоподобия L

$$L(\vec{x}, \theta) = \prod_{k=1}^n p(x_k, \theta)$$

Также есть $\hat{\theta}$ — несмещённая оценка параметра θ . Как улучшить $\hat{\theta}$?

Возьмём статистику $T = T(\vec{x})$, обладающую определёнными свойствами. Тогда улучшенной оценкой θ будет условное математическое ожидание $M[\hat{\theta} \mid T]$.

О свойствах, которыми должна обладать статистика T , поговорим позже. Одно ясно уже сейчас: T является функцией от выборки \vec{x} , как и оценка $\hat{\theta}$. Это значит, что нам не нужно погружаться в слишком абстрактные размышления, а достаточно выяснить, как считать математическое ожидание одной функции выборки (случайного вектора) $f(\vec{x})$ при условии другой функции $g(\vec{x})$ той же выборки \vec{x} .

$$f, g : \mathbb{R}^n \rightarrow \mathbb{R}$$

Вспомним, что для поиска условного математического ожидания мы находили функцию $\varphi^\eta(x) = M[\eta \mid \xi = x]$. Тут изменилось совсем немного — лишь обозначения: вместо η у нас $f(\vec{x})$, а вместо ξ тут $g(\vec{x})$. Значит, нужно найти вид такого условного математического ожидания

$$M[f(\vec{x}) \mid g(\vec{x}) = t] = ?$$

Для начала нужно понять, что из себя представляет множество точек $S_t = \{\vec{u} \mid g(\vec{u}) = t\}$.

Очевидно, что функция $g(\vec{x})$ описывает скалярное поле в n -мерном пространстве. А для скалярного поля множество S_t имеет своё название — поверхность уровня (изоповерхность) — то есть, поверхность, на которой функция принимает одно и то же значение.

Для понимания ситуации рассмотрим несколько примеров.

Пример 2.4.12

Имеем двумерное пространство

$$n = 2, g : \mathbb{R}^2 \rightarrow \mathbb{R}$$

Функция $g(x, y)$ будет возвращать первую координату

$$g(x, y) = x$$

Очевидно, что поверхности уровней — вертикальные линии (параллельные оси ординат), так как при изменении y значение функции не меняется

$$S_t = \{(x, y) \mid g(x, y) = t\} = \{(x, y) \mid x = t\}$$

Пример 2.4.13

Опять возьмём двумерное пространство

$$n = 2, g : \mathbb{R}^2 \rightarrow \mathbb{R}$$

В этот раз функция $g(x, y)$ будет квадратом расстояния от начала координат $(0, 0)$ до точки (x, y)

$$g(x, y) = x^2 + y^2$$

Тут поверхностями уровня будут окружности радиуса \sqrt{t} , так как окружность по определению является геометрическим местом точек, равноудалённых от определённой точки (расстояния до которых одинаковые)

$$S_t = \{(x, y) \mid x^2 + y^2 = t\} = \{(x, y) \mid x^2 + y^2 = \sqrt{t}^2\}$$

Пример 2.4.14

Рассмотрим n -мерное пространство ($n \geq 1$). Возьмём единичный вектор $\vec{e} : \|\vec{e}\| = 1$. Функция g будет скалярным произведением аргумента \vec{u} с только что определённым единичным вектором \vec{e}

$$g(\vec{u}) = (\vec{u}, \vec{e})$$

В таком случае поверхностью уровня S_t будет гиперплоскость, проходящая через точку $t \cdot \vec{e}$, с нормалью \vec{e} , которую описывает следующее уравнение^a

$$S_t = \{\vec{u} \mid (\vec{u}, \vec{e}) = t\}$$

^a Уравнение гиперплоскости с нормалью \vec{e} , проходящую через точку с радиус-

вектором \vec{x} , выглядит следующим образом

$$(\vec{u}, \vec{e}) = (\vec{x}, \vec{e})$$

Вследствие линейности скалярного произведения получаем

$$(t \cdot \vec{e}, \vec{e}) = t \cdot (\vec{e}, \vec{e}) = t$$

Значит, указав $\vec{x} = t \cdot \vec{e}$, получим уравнение, данное в примере

$$(\vec{u}, \vec{e}) = (\vec{x}, \vec{e}) = (t \cdot \vec{e}, \vec{e}) = t \cdot (\vec{e}, \vec{e}) = t$$

В примерах увидели, что получаемые поверхности уровня не имеют объёма в n -мерном пространстве, но у них есть площадь — $(n - 1)$ -мерный объём.

Опираясь на предыдущий опыт (для величин с совместной плотностью), хотелось бы найти совместную плотность случайных величин $f(\vec{x})$ и $g(\vec{x})$. И оказывается, что это желание является верной догадкой.

Нетрудно догадаться, что для того, чтобы найти “вес” поверхности уровня, нужно будет взять поверхностный интеграл от плотности.

Чтобы мы не получали нулевой вес поверхности $S_t = \{g(\vec{x}) = t\}$, будем считать объём её раздутия. Поместим поверхность в своеобразный кокон, толщина которого в каждой точке будет тем меньше, чем больше скорость перехода в этой точке от текущего уровня к следующему.

Чтобы значение t было близким к $g(\vec{u})$, нужно, чтобы точка \vec{u} была близка к поверхности S_t . Обозначим расстояние между t и $g(\vec{u})$ как $\tilde{\varepsilon}$, а расстояние между точкой \vec{u} и поверхностью S_t как ε . Чему равны эти расстояния, будет выяснено ниже, а значение t и точки \vec{u} будет ясно из контекста.

Вероятность того, что значение $g(\vec{x})$ отдалено от t не больше, чем на $\tilde{\varepsilon}$, будет приблизительно равна плотности распределения $g(\vec{x})$ в этой точке (если таковая имеется), умноженной на это расстояние — погрешность, которая нас устроит (потом мы, естественно, устремим её к нулю). Обозначим плотность случайной величины $g(\vec{x})$ в точке t через $q(t)$

$$\mathbb{P}\{g(\vec{x}) \in [t - \tilde{\varepsilon}, t + \tilde{\varepsilon}]\} \approx q(t) \cdot 2 \cdot \tilde{\varepsilon}$$

Вернёмся к раздутию. Помним, что ε — расстояние от точки \vec{u} до ближайшей к нему точки кокона, а также то, что это расстояние должно быть обратно пропорционально стремительности изменения уровней в этой окрестности. Понимаем, что нам необходима численная мера этой скорости. Под описание такой величины прекрасно подходит модуль градиента. Поскольку значение $g(\vec{x})$ не меняется вдоль поверхности S_t и равно t , то градиент будет направлен по нормали к данной точке поверхности.

Норма градиента — отношение прироста функции к приросту координат. Нас интересует прирост координат ε в окрестности точки \vec{u} , мы располагаем приростом функции $\tilde{\varepsilon}$ и нормой градиента $\|\vec{\nabla} \cdot g(\vec{u})\|$. Напрашивается формула

$$\varepsilon \approx \frac{\tilde{\varepsilon}}{\|\vec{\nabla} \cdot g(\vec{u})\|} \quad (2.13)$$

Обозначим раздутие поверхности S_t как $G_{\tilde{\varepsilon}}$, тогда вероятность попадания значения $g(\vec{x})$ в коридорчик ширины $\tilde{\varepsilon}$ будет приблизительно равно интегралу плотности распределения вектора \vec{x} по этому коридорчику

$$\mathbb{P}\{g(\vec{x}) \in [t - \tilde{\varepsilon}, t + \tilde{\varepsilon}]\} \approx q(t) \cdot 2 \cdot \tilde{\varepsilon} \approx \int_{G_{\tilde{\varepsilon}}} p(\vec{u}) d\vec{u}$$

Следовательно, у нас почти готова формула для плотности $q(t)$ случайной величины $g(\vec{x})$

$$q(t) \cdot 2 \cdot \tilde{\varepsilon} \approx \int_{G_{\tilde{\varepsilon}}} p(\vec{u}) d\vec{u} \Rightarrow q(t) \approx \frac{1}{2 \cdot \tilde{\varepsilon}} \cdot \int_{G_{\tilde{\varepsilon}}} p(\vec{u}) d\vec{u}$$

Чтобы убрать неточность и было обычное равенство, устремим ширину коридорчика к нулю

$$q(t) = \lim_{\tilde{\varepsilon} \rightarrow 0} \frac{1}{2 \cdot \tilde{\varepsilon}} \cdot \int_{G_{\tilde{\varepsilon}}} p(\vec{u}) d\vec{u} \quad (2.14)$$

Распишем $\tilde{\varepsilon}$, воспользовавшись формулой (2.13)

$$\varepsilon \approx \frac{\tilde{\varepsilon}}{\left\| \vec{\nabla} \cdot g(\vec{u}) \right\|} \Rightarrow \tilde{\varepsilon} \approx \varepsilon \cdot \left\| \vec{\nabla} \cdot g(\vec{u}) \right\|$$

Вернёмся к плотности в формуле (2.14). Заменяя $\tilde{\varepsilon}$ на $\varepsilon \cdot \left\| \vec{\nabla} \cdot g(\vec{u}) \right\|$, нужно разобраться, что теперь нужно устремлять к нулю. Поскольку модуль градиента — величина, зависящая от координат, и стремиться к нулю будет лишь при изменении поведения функции, то устремлять будем ε (толщину кокона)

$$q(t) = \lim_{\tilde{\varepsilon} \rightarrow 0} \frac{1}{2 \cdot \tilde{\varepsilon}} \cdot \int_{G_{\tilde{\varepsilon}}} p(\vec{u}) d\vec{u} = \lim_{\varepsilon \rightarrow 0} \frac{1}{2 \cdot \varepsilon \cdot \left\| \vec{\nabla} \cdot g(\vec{u}) \right\|} \cdot \int_{G_{\tilde{\varepsilon}}} p(\vec{u}) d\vec{u}$$

Поскольку ε играет роль половины толщины (отсюда и возникает множитель двойка), а $d\vec{u}$ — маленький элемент объёма, то при делении объёма на толщину получим площадь. Поскольку толщина стремится к нулю, то она становится соразмерна с объёмом и мы получаем ненулевое значение площади, а коридорчик $G_{\tilde{\varepsilon}}$ вырождается в поверхность уровня S_t . Обозначив меру площади на поверхности S_t как $\sigma_t(d\vec{u})$, получаем поверхностный интеграл первого рода

$$q(t) = \int_{S_t} p(\vec{u}) \cdot \frac{1}{\left\| \vec{\nabla} \cdot g(\vec{u}) \right\|} \sigma_t(d\vec{u}) \quad (2.15)$$

А теперь вспомним, как обстояло дело со случайными величинами, имеющими совместную плотность (2.11)

$$\varphi^\eta(x) = \frac{\int_{\mathbb{R}} y \cdot p(x, y) dy}{r(x)} = \frac{\int_{\mathbb{R}} y \cdot p(x, y) dy}{\int_{\mathbb{R}} p(x, y) dy}$$

В знаменателе у нас стоял вес поверхности уровня, раскрыв который, мы получали интеграл от совместной плотности. Что же есть у нас? Вес поверхности уровня — функция одного аргумента $q(t)$, которая равна интегралу от плотности по всей той части пространства, где случайная величина $g(\vec{x})$ принимает одно и то же значение t — по поверхности уровня S_t .

То есть, в нашем случае роль \mathbb{R} играет поверхность S_t , роль совместной плотности $p(x, y)$ играет плотность случайного вектора $p(\vec{u})$, а вместо дифференциала dy у нас мера площади, делённая на норму градиента $\frac{\sigma_t(d\vec{u})}{\|\vec{\nabla} \cdot g(\vec{u})\|}$. В числителе дроби в формуле (2.11) стоит y , в нашем же случае это функция $f(\vec{u})$, поскольку там случайная величина присутствовала в плотности сама по себе, тут же у нас есть плотность случайного вектора $p(\vec{x})$, а найти нужно среднее функции случайной величины $f(\vec{x})$. Итого, получается переход

$$\frac{\int_{\mathbb{R}} y \cdot p(x, y) dy}{r(x)} \rightarrow \frac{\int_{S_t} f(\vec{u}) \cdot p(\vec{u}) \frac{\sigma_t(d\vec{u})}{\|\vec{\nabla} \cdot g(\vec{u})\|}}{q(t)}$$

И конечная формула

$$M[f(\vec{x}) | g(\vec{x}) = t] = \frac{\int_{S_t} f(\vec{u}) \cdot p(\vec{u}) \cdot \frac{1}{\|\vec{\nabla} \cdot g(\vec{u})\|} \sigma_t(d\vec{u})}{\int_{S_t} p(\vec{u}) \cdot \frac{1}{\|\vec{\nabla} \cdot g(\vec{u})\|} \sigma_t(d\vec{u})}$$

Теорема 2.4.15: Условное математическое ожидание гладких функций

Если есть случайный вектор \vec{x} с известной плотностью распределения $p(\vec{x})$, а также гладкая функция $g(\vec{x})$ с невырожденным градиентом, то математическое ожидание случайной величины $f(\vec{x})$ при условии $g(\vec{x}) = t$ считается по формуле

$$M[f(\vec{x}) | g(\vec{x}) = t] = \frac{\int_{S_t} f(\vec{u}) \cdot p(\vec{u}) \cdot \frac{1}{\|\vec{\nabla} \cdot g(\vec{u})\|} \sigma_t(d\vec{u})}{\int_{S_t} p(\vec{u}) \cdot \frac{1}{\|\vec{\nabla} \cdot g(\vec{u})\|} \sigma_t(d\vec{u})}$$

Замечание 2.4.16

Формула остаётся справедливой, если поверхности уровня функции g состоят из нескольких гладких кусков.

2.4.6 Пример

Поскольку этот пример оказался достаточно громоздким, было решено посвятить ему целый подраздел.

Есть выборка x_1, \dots, x_n из равномерного распределения с на отрезке $[0, \theta]$. Нужно посчитать условное математическое ожидание первого элемента выборки $f(\vec{x}) = x_1$ при условии максимального $g(\vec{x}) = x_{(n)}$

$$M[x_1 \mid x_{(n)}] = ?$$

Поверхности уровня

Для начала сообразим, что из себя представляет поверхность уровня S_t

$$S_t = \left\{ \vec{u} \mid u_i \geq 0, \max_{i=1, n} u_i = t \right\}$$

На двумерной плоскости это будет два отрезка, перпендикулярных друг другу и осям. Они будут выходить из точки (t, t) и заканчиваться на осях.

Рассмотрим, почему всё именно так

1. Нас не устраивают точки, которые находятся за пределами квадрата, ограниченного прямыми, проходящими через точки $(0, t)$ и $(t, 0)$, так как в таком случае максимум будет больше t , что по условию быть не может
2. Максимальное значение зафиксировано, а это значит, что хотя бы одна координата должна всегда равняться максимуму

Таким образом, закрасив квадрат, нижняя левая грань которого находится в начале координат, а верхняя правая в точке (t, t) , удаляем все те точки, где нет такой координаты, которая равна t . Все точки внутри контура пропадут, так как лишь на контуре квадрата могут находиться точки, имеющие хоть одну координату равной t . Теперь осталось отбросить те отрезки, что лежат на координатных осях, потому что на них у точек меняется лишь одна координата (например, на оси ординат меняется лишь x , а $y = 0$ на всей оси), а желаемое значение t принимается лишь на самом конце отрезка, но это лишь одна точка, и в пространстве размерностью $n \geq 1$ имеет меру Лебега 0, поэтому её тоже можно отбросить.

Так уж получилось, что только что был выведен практически универсальный способ построения поверхности уровня $g(\vec{u}) = \max_{i=1, n} u_i = t$. Осталось лишь ввести небольшие правки и распространить его на пространство размерности n .

Например, в трёхмерном пространстве поверхностью уровня будет совокупность граней куба, где исключены те грани, что соприкасаются с одной из осей — те грани, одна точка которых находится в начале координат $(0, 0)$.

Так же будет и в многомерном пространстве — чертим гиперкуб и отбрасываем те его грани, один из углов которых находится в начале координат.

Также отметим, что каждая грань перпендикулярна $n - 1$ осям, а пересекается с ними лишь в точках со значением t . Так как нельзя провести две разные гиперплоскости, имеющих одну нормаль и проходящих через одну точку (гиперплоскость по определению определяется этой парой), то делаем вывод: поверхность S_t у нас состоит из n граней.

Норма градиента

Найдём норму градиента функции $g(\vec{x}) = \max_{i=1,n} x_i$.

Возможны два случая:

1. Максимальный элемент в векторе один
2. Максимальных элементов в векторе несколько (от двух до n) и они равны друг другу (если $n \geq 2$)

Рассмотрим первый случай. Без потери общности предположим, что максимальный элемент — первый

$$\max_{i=1,n} x_i = x_1$$

Очевидно, что очень малое изменение x_1 приведёт к очень малому (причём такому же) изменению максимального элемента выборки. Грубо говоря, если у нас есть числа $x_1 = 3, x_2 = 2, x_3 = 1$, то максимальное из них — x_1 . Если оно изменится на 1 в какую-либо сторону, то максимальное значение выборки изменится так же на 1.

Мы это всё рассматриваем для того, чтобы показать, что производная по максимальной координате будет равна единице, так как производная — отношение очень малого прироста функции к очень малому изменению аргумента (который привёл к такому изменению функции). Даже если у нас были числа $x_1 = 1$ и $x_2 = 1.001$, мы всё равно сможем найти такой маленький прирост $\delta < 0.001$ (между двумя разными действительными числами найдётся ещё континуальное число действительных чисел, поэтому такое δ найдётся всегда), при котором x_2 останется максимальным элементом и прирост градиента по этой координате будет равен приросту самой координаты.

Не забываем, что мы сейчас рассматриваем тот случай, когда максимальное значение одно, а это значит, что остальные значения выборки строго меньше максимального.

Поскольку очень малые изменения других элементов выборки не приведут к тому, что они станут максимальными (а если приведут, то возьмём ещё более маленький прирост), то их изменение не повлияет на значение функции g , а это значит, что частные производные по ним обращаются в нули.

Итого, к чему мы пришли. Когда x_1 является максимальным элементом выборки, то градиент функции g в точке \vec{x} равен

$$\vec{\nabla} \cdot g(\vec{x}) = \frac{\partial g}{\partial x_1} \cdot \vec{e}_1 + \frac{\partial g}{\partial x_2} \cdot \vec{e}_2 + \dots + \frac{\partial g}{\partial x_n} \cdot \vec{e}_n = \vec{e}_1 + 0 + \dots + 0 = \vec{e}_1$$

Когда у нас не x_1 является максимальным элементом, а x_k , где $1 \leq k \leq n$, то очевидно, что результат будет следующим:

$$\vec{\nabla} \cdot g(\vec{x}) = \vec{e}_k$$

Нас интересует лишь норма градиента, которая в данном случае равна единице

$$\|\vec{\nabla} \cdot g(\vec{x})\| = \|\vec{e}_k\| = 1$$

Второй случай (когда несколько элементов максимальны и равны между собой) нас не интересует, так как такое возможно лишь на рёбрах ($n \geq 3$) и в точках пересечения рёбер ($n \geq 2$). Что те, что другие (прямые и точки в пространстве) имеют нулевой объём. В одномерном пространстве (с одной осью) у нас есть лишь одна случайная величина, и она же является максимальной.

Условное математическое ожидание относительно события

Посчитаем условное математическое ожидание по формуле

$$M[x_1 \mid x_{(n)} = t] = \frac{\int_{S_t} u_1 \cdot \theta^{-n} \cdot \frac{1}{1} \sigma_t(d\vec{u})}{\int_{S_t} \theta^{-n} \cdot \frac{1}{1} \sigma_t(d\vec{u})} = \frac{\int_{S_t} u_1 \sigma_t(d\vec{u})}{\int_{S_t} \sigma_t(d\vec{u})}$$

Поверхность уровня S_t в верхнем интеграле можно (и нужно!) разбить на две части: ту, где u_1 меняется, и ту, где u_1 принимает постоянное значение.

Вспоминаем, что поверхность S_t — часть гиперкуба, содержащая лишь грани, на которых которых та случайная величина, что не меняется, имеет значение t (максимум). Частью поверхности, на которой u_1 принимает постоянное значение t , будет одна грань — та грань гиперкуба, что проходит через точку $u_1 = t$ и перпендикулярна оси (вектору \vec{e}_1).

Обозначим грань, где $u_1 = t$, как U_t , а оставшуюся часть поверхности как $Y_t = S_t \setminus U_t$.

Имеем более конкретную формулу для подсчёта условного математического ожидания

$$M[x_1 \mid x_{(n)} = t] = \frac{\int_{S_t} u_1 \sigma_t(d\vec{u})}{\int_{S_t} \sigma_t(d\vec{u})} = \frac{\int_{U_t} u_1 \Big|_{u_1=t} \sigma_t(d\vec{u}) + \int_{Y_t} u_1 \sigma_t(d\vec{u})}{\int_{S_t} \sigma_t(d\vec{u})}$$

Вспоминаем, что имеется n граней, а это значит, что в знаменателе у нас n объёмов $(n-1)$ -мерных гиперкубов (n площадей n -мерных квадратов) со стороной t , которые в свою очередь равняются числу t^{n-1} .

В числителе у нас два интеграла. Первый интеграл — интеграл по одной грани, что опять же является $(n-1)$ -мерным объёмом (n -мерной площадью). Не забываем про константу t , что там находится: она умножается на результат интегрирования t^{n-1} и в результате получаем t^n .

Теперь подошли к самому сложному кусочку этой дроби — интеграл по оставшимся $n-1$ граням. Поскольку интеграл не зависит ни от чего кроме u_1 , то мы преспокойнейше можем вынести $(n-2)$ -мерный объём, а по оставшемуся измерению придётся интегрировать от 0 до t

$$\frac{\int_{U_t} u_1 \Big|_{u_1=t} \sigma_t(d\vec{u}) + \int_{Y_t} u_1 \sigma_t(d\vec{u})}{\int_{S_t} \sigma_t(d\vec{u})} = \frac{t^n + (n-1) \cdot t^{n-2} \cdot \int_0^t u_1 du_1}{n \cdot t^{n-1}}$$

Дальше идут нехитрые математические преобразования, которые называются интегрированием

$$\begin{aligned} M[x_1 \mid x_{(n)} = t] &= \frac{t^n + (n-1) \cdot t^{n-2} \cdot \int_0^t u_1 du_1}{n \cdot t^{n-1}} = \\ &= \frac{t^n + (n-1) \cdot t^{n-2} \cdot \frac{t^2}{2}}{n \cdot t^{n-1}} = \frac{t + (n-1) \cdot t \cdot \frac{1}{2}}{n} = t \cdot \frac{n+1}{2 \cdot n} \end{aligned}$$

Условное математическое ожидание

Мы получили условное математическое ожидание относительно события $\{g(x) = t\}$ — конкретное значение $t \cdot \frac{n+1}{2 \cdot n}$. Чтобы получить условное математическое ожидание одной случайной величины относительно другой, нужно лишь подставить вместо t наше значение $g(\vec{x}) = x_{(n)}$

$$M[x_1 \mid x_{(n)}] = M[x_1 \mid x_{(n)} = t] \Big|_{t=x_{(n)}} = t \cdot \frac{n+1}{2 \cdot n} \Big|_{t=x_{(n)}} = x_{(n)} \cdot \frac{n+1}{2 \cdot n}$$

Видим, что получили случайную величину, которая не зависит от параметра θ , а это значит, что мы на правильном пути

$$M[x_1 \mid x_{(n)}] = \frac{n+1}{2 \cdot n} \cdot x_{(n)}$$

Проверка

Проведём небольшую очевидную проверку: положим $n = 1$ (одна случайная величина, одномерное пространство). Тогда формула примет следующий вид

$$M[x_1 \mid x_{(1)}] = \frac{1+1}{2 \cdot 1} \cdot x_{(1)} = \frac{2}{2} \cdot x_{(1)} = x_{(1)} = x_1$$

Всё сходится с нашими интуитивными предположениями: у нас имеется лишь один элемент в выборке, а мы знаем значение максимального. Значит, мы знаем значение этого единственного элемента (иначе кому ещё быть максимальным в этой выборке?).

2.5 Условные распределения

Определение 2.5.1: Условное распределение

Условное распределение случайной величины ξ при известной σ -алгебре \mathfrak{F}_1 — это функция π

$$\pi : \Omega \times \mathfrak{B} \rightarrow [0, 1]$$

Функция π должна обладать следующими свойствами

1. На любом элементе Δ борелевского множества \mathfrak{F}_1 функция $\pi(\cdot, \Delta)$ является измеримой относительно \mathfrak{F}_1

2. На любом элементарном исходе из множества Ω функция $\pi(\omega, \cdot)$ является вероятностной мерой

3. Выполняется равенство

$$\forall \Delta \in \mathfrak{B} : \pi(\cdot, \Delta) = M[\mathbb{1}\{\xi \in \Delta\} \mid \mathfrak{F}_1]$$

Это равенство нам уже знакомо, поэтому ничего принципиально нового не добавилось

$$\mathbb{P}(\xi \in \Delta) = M\mathbb{1}\{\xi \in \Delta\}$$

Обозначение

$$\pi(\cdot, \Delta) = \mathbb{P}(\xi \in \Delta \mid \mathfrak{F}_1)$$

Если же σ -алгебра \mathfrak{F}_1 порождена случайной величиной η : $\mathfrak{F}_1 = \sigma(\eta)$, работает следующее обозначение

$$\mathbb{P}(\xi \in \Delta \mid \sigma(\eta)) = p(\eta, \Delta)$$

Когда нас интересует событие $\eta = t$, работает следующее обозначение

$$\mathbb{P}(t, \Delta) = p(\xi \in \Delta \mid \eta = t)$$

Связь с условным математическим ожиданием

$$M[f(\xi) \mid \eta = t] = \int_{\mathbb{R}} f(u) p(t, du)$$

Замечание 2.5.2

В обозначениях выше точка вместо аргумента означает, что на выходе мы получаем не определённое значение, а функцию от того аргумента, который заменён точкой.

Например, запись $\pi(\cdot, \Delta)$ означает некую функцию ρ

$$\rho : \Omega \rightarrow [0, 1]$$

Значение этой функции будет считаться по формуле

$$\rho(\omega) = \pi(\omega, \Delta)$$

Рассмотрим примеры вычисления условных распределений

Пример 2.5.3: См. пример 2.4.8

Случайные величины ξ и η имеют совместное дискретное распределение

$$\mathbb{P}\{\xi = a_i, \eta = b_j\} = p_{ij}$$

В таком случае условное распределение считается по формуле

$$\mathbb{P}\{\xi = a_i, \eta = b_j\} = \frac{p_{ij}}{\sum_j p_{ij}}$$

Пример 2.5.4: См. формулу 2.11

Случайные величины ξ и η имеют совместную плотность распределения $p(x, y)$

$$\frac{\int_{\Delta} y \cdot p(x, y) dy}{\int_{\mathbb{R}} p(x, y) dy}$$

Пример 2.5.5: См. теорему 2.4.15

У случайного вектора \vec{x} есть плотность распределения $p(\vec{u})$. Тогда условное распределение $f(\vec{x})$ относительно гладкой функции $g(\vec{x})$ считается по формуле

$$\mathbb{P}(f(\vec{x}) \in \Delta \mid g(\vec{x}) = t) = \frac{\int_{S_t \cap \Delta} p(\vec{u}) \cdot \frac{1}{\|\vec{\nabla} \cdot g(\vec{u})\|} \sigma_t(d\vec{u})}{\int_{S_t} p(\vec{u}) \cdot \frac{1}{\|\vec{\nabla} \cdot g(\vec{u})\|} \sigma_t(d\vec{u})}$$

2.6 Достаточные статистики

Как говорилось в подразделе 2.4.5, условное математическое ожидание нам понадобилось из-за наличия статистик T , обладающих особыми свойствами. Пришло время о них поговорить

Определение 2.6.1: Достаточная статистика

Статистика $T(x_1, x_2, \dots, x_n)$ — достаточная статистика для параметра θ , если условное распределение выборки при известном T не зависит от θ

Осмыслим написанное

1. Речь идёт об условном распределении всей выборки. Никаких новых инструментов, к счастью, не появилось:

$$\pi(T, \Delta) = \mathbb{P}(\vec{x} \in \Delta \mid T)$$

2. Почему возникает определение достаточных статистик? Пускай T — достаточная статистика. Как с её помощью получить распределение всей выборки?

$$\mathbb{P}\{\vec{x} \in \Delta\} = \mathbb{M}\mathbb{1}\{\vec{x} \in \Delta\}$$

Далее воспользуемся I свойством условного математического ожидания (формула полной вероятности)

$$M\mathbb{1}\{\vec{x} \in \Delta\} = MM[\mathbb{1}\{\vec{x} \in \Delta\} | T]$$

Помним, что условное математическое ожидание относительно σ -алгебры, порождённой случайной величиной T (функция случайного вектора является случайной величиной), является случайной величиной, измеримой относительно $\sigma(T)$. Мы также помним, что “быть измеримой относительно σ -алгебры, порождённой случайной величиной T ”, это то же самое, что “быть функцией случайной величины T ” (утверждение 2.3.1), а это значит, что существует функция f такая, что

$$M[\mathbb{1}\{\vec{x} \in \Delta | T\}] = f(T)$$

Тогда получаем такое красивое равенство

$$\mathbb{P}\{\vec{x} \in \Delta\} = Mf(T)$$

Теорема 2.6.2: Об улучшении оценки с помощью достаточной статистики

Пусть x_1, \dots, x_n — выборка из распределения $F_\theta(x)$, $\theta \in \Theta$. Есть T — достаточная статистика для параметра θ , а также несмещённая оценка $\hat{\theta}$ параметра θ . Введём оценку θ_*

$$\theta_* = M[\hat{\theta} | T]$$

Оценка θ_* не хуже, чем оценка $\hat{\theta}$

$$\begin{cases} M_\theta \theta_* = \theta \\ D_\theta \theta_* \leq D_\theta \hat{\theta} \end{cases}$$

Замечание 2.6.3

Оценка $\theta_* = M[\hat{\theta} | T]$ не зависит от θ , так как T — достаточная статистика

Замечание 2.6.4

“Как правило”, одномерная достаточная статистика для одномерного параметра даёт не улучшаемую статистику

Доказательство. 1. С первым пунктом всё просто: пользуемся формулой полной вероятности (I свойство)

$$M_\theta \theta_* = M_\theta M[\hat{\theta} | T] = M_\theta \hat{\theta} = \theta$$

2. Тут же доказательство пройдёт в несколько этапов.

Сначала распишем дисперсию и оценку θ_* по определению

$$D_\theta \theta_* = M_\theta (\theta_* - \theta)^2 = M_\theta \left(M[\hat{\theta} | T] - \theta \right)^2$$

Поскольку T — достаточная статистика и не зависит от θ , то θ измерима относительно $\sigma(T)$ и является константой. Значит, можно переписать статистику θ как условное математическое ожидание (V свойство), а затем воспользоваться линейностью условного математического ожидания (VIII свойство)

$$\begin{aligned} M_\theta \left(M[\hat{\theta} | T] - \theta \right)^2 &= M_\theta \left(M[\hat{\theta} | T] - M[\theta | T] \right)^2 = \\ &= M_\theta \left(M[(\hat{\theta} - \theta) | T] \right)^2 \end{aligned}$$

Дальше воспользуемся неравенством Йенсена (III свойство) и формулой полной вероятности (I свойство)

$$\begin{aligned} M_\theta \left(M[(\hat{\theta} - \theta) | T] \right)^2 &\leq M_\theta M \left[(\hat{\theta} - \theta)^2 | T \right] = \\ &= M_\theta (\hat{\theta} - \theta)^2 = D_\theta \hat{\theta} \end{aligned}$$

□

Замечание 2.6.5

Равенство в неравенстве Йенсена выше возможно, когда условное распределение вырождается в одну точку. Когда условное распределение не вырождено, то неравенство оказывается строгим.

Замечание 2.6.6

Оценка $\theta_* = M[\hat{\theta} | T]$ измерима относительно T по определению условного математического ожидания, а это значит, что она является функцией от T .

Пусть $\tilde{\theta}$ — оптимальная несмещённая оценка. Тогда $\theta_* = M[\hat{\theta} | T]$ — оптимальная, а значит, эти оценки равны $\theta_* = \tilde{\theta}$ по теореме единственности (теорема Колмогорова 1.2.1), поскольку оптимальная оценка либо одна, либо не существует вовсе. Значит, оптимальная оценка — функция достаточной статистики.

Теорема 2.6.7: Факторизационная теорема

Пусть x_1, \dots, x_n — выборка из распределения с плотностью $p(x, \theta)$, $\theta \in \Theta$.

Статистика T является достаточной тогда и только тогда, когда функция правдоподобия $L(\vec{x}, \theta)$ допускает факторизацию, то есть может быть представлена произведением двух функций следующего вида

$$L(\vec{x}, \theta) = h(T, \theta) \cdot g(\vec{x})$$

Замечание 2.6.8

Также с теоремой и её доказательствами можно ознакомиться в источниках [6, стр. 78], [1, стр. 158].

Наброски доказательства для гладкой функции правдоподобия. Условное распределение выборки при известной статистике $T = f(\vec{x})$ определяется формулой

$$\mathbb{P}(\vec{x} \in \Delta \mid T = t) = \frac{\int_{S_t \cap \Delta} L(\vec{u}, \theta) \cdot \frac{1}{\|\vec{\nabla} \cdot f(\vec{u})\|} \sigma_t(d\vec{u})}{\int_{S_t} L(\vec{u}, \theta) \cdot \frac{1}{\|\vec{\nabla} \cdot f(\vec{u})\|} \sigma_t(d\vec{u})} \quad (2.16)$$

Достаточность Пусть функция правдоподобия допускает факторизацию, то есть существуют такие функции $h(T, \theta)$ и $g(\vec{x})$, что

$$L(\vec{x}, \theta) = h(T, \theta) \cdot g(\vec{x})$$

Тогда интеграл (2.16) примет следующий вид

$$\mathbb{P}(\vec{x} \in \Delta \mid T = t) = \frac{\int_{S_t \cap \Delta} h(T, \theta) \cdot g(\vec{u}) \cdot \frac{1}{\|\vec{\nabla} \cdot f(\vec{u})\|} \sigma_t(d\vec{u})}{\int_{S_t} h(T, \theta) \cdot g(\vec{u}) \cdot \frac{1}{\|\vec{\nabla} \cdot f(\vec{u})\|} \sigma_t(d\vec{u})}$$

Хоть T и является функцией выборки, мы зафиксировали его значение, а θ является константой. Это значит, что функция $h(T, \theta)$ тоже не зависит от \vec{u} , поэтому сверху и снизу её можно сократить, избавив зависимость распределения от параметра θ

$$\mathbb{P}(\vec{x} \in \Delta \mid T = t) = \frac{\int_{S_t \cap \Delta} g(\vec{u}) \cdot \frac{1}{\|\vec{\nabla} \cdot f(\vec{u})\|} \sigma_t(d\vec{u})}{\int_{S_t} g(\vec{u}) \cdot \frac{1}{\|\vec{\nabla} \cdot f(\vec{u})\|} \sigma_t(d\vec{u})}$$

Условное распределение \vec{x} не зависит от θ при известном T , что и требовалось доказать для того, чтобы показать достаточность факторизации.

Необходимость Пускай T — достаточная статистика. Выпишем плотность распределения T в точке t согласно формуле (2.15), но с небольшими поправками: плотность распределения выборки \vec{x} заменяется функцией правдоподобия, а плотность T будет зависеть не только от t , но и от параметра

θ .

$$q(t, \theta) = \int_{S_t} L(\vec{u}, \theta) \cdot \frac{1}{\|\vec{\nabla} \cdot f(\vec{u})\|} \sigma_t(d\vec{u})$$

Поверхностная мера $\sigma_t(\vec{u})$ не зависит от параметра θ , а это значит, что можно смело поделить обе части равенства на $q(t, \theta)$ и внести плотность под знак интеграла.

$$\int_{S_t} \frac{1}{q(t, \theta)} \cdot L(\vec{u}, \theta) \cdot \frac{1}{\|\vec{\nabla} \cdot f(\vec{u})\|} \sigma_t(d\vec{u}) = 1$$

Область интегрирования и мера не зависят от θ , а это значит, что и подынтегральное выражение тоже не зависит от θ , а зависит лишь от вектора \vec{u}

$$\frac{1}{q(t, \theta)} \cdot L(\vec{u}, \theta) \cdot \frac{1}{\|\vec{\nabla} \cdot f(\vec{u})\|} = c(\vec{u})$$

Значит, функция правдоподобия представима в следующем виде

$$L(\vec{u}, \theta) = q(t, \theta) \cdot \|\vec{\nabla} \cdot f(\vec{u})\| \cdot c(\vec{u})$$

И тут мы видим, что это и есть факторизация!

Для начала вспомним, что у нас распределение при условии $T = t$, а это значит, что плотность $q(t, \theta)$ может быть расписана следующим образом

$$q(t, \theta) = q(T, \theta)$$

Теперь, выделив функции g и h , получаем необходимый результат

$$\begin{cases} L(\vec{u}, \theta) = q(t, \theta) \cdot \|\vec{\nabla} \cdot f(\vec{u})\| \cdot c(\vec{u}) \\ h(T, \theta) = q(T, \theta) = q(t, \theta) \\ g(\vec{u}) = \|\vec{\nabla} \cdot f(\vec{u})\| \cdot c(\vec{u}) \end{cases} \Rightarrow L(\vec{u}, \theta) = g(\vec{u}) \cdot h(T, \theta)$$

То есть, чтобы T было достаточной статистикой, необходимо, чтобы функция правдоподобия допускала факторизацию.

□

Замечание 2.6.9

Теорема остаётся справедливой для дискретных распределений, где функция правдоподобия выглядит следующим образом

$$L(\vec{u}, \theta) = \prod_{k=1}^n \mathbb{P}\{x_k = u_k\}$$

Пример 2.6.10

x_1, \dots, x_n — выборка из нормального распределения с неизвестным математическим ожиданием $N(\theta, 1)$, $\theta \in \mathbb{R}$.

Рассмотрим функцию правдоподобия и вытянем из неё что-то полезное

$$L(\vec{x}, \theta) = \frac{1}{\sqrt{2 \cdot \pi}^n} \cdot \exp \left\{ -\frac{1}{2} \cdot \sum_{k=1}^n (x_k - \theta)^2 \right\}$$

Рассмотрим сумму и выделим из неё выборочное среднее

$$\begin{aligned} \sum_{k=1}^n (x_k - \theta)^2 &= \sum_{k=1}^n x_k^2 - 2 \cdot \theta \cdot \sum_{k=1}^n x_k + n \cdot \theta^2 = \\ &= \sum_{k=1}^n x_k^2 - 2 \cdot \theta \cdot n \cdot \bar{x} + n \cdot \theta^2 \end{aligned}$$

Теперь выделим квадрат разности выборочного среднего и параметра θ

$$\begin{aligned} &\sum_{k=1}^n x_k^2 - 2 \cdot \theta \cdot n \cdot \bar{x} + n \cdot \theta^2 = \\ &= \sum_{k=1}^n x_k^2 - 2 \cdot \theta \cdot n \cdot \bar{x} + n \cdot \theta^2 + n \cdot \bar{x}^2 - n \cdot \bar{x}^2 = \\ &= \sum_{k=1}^n (x_k^2 - \bar{x}^2) + n \cdot (\bar{x} - \theta)^2 \end{aligned}$$

Вернёмся к исходному выражению и видим экспоненту суммы. Заменим её на произведение экспонент

$$\begin{aligned} &\frac{1}{\sqrt{2 \cdot \pi}^n} \cdot \exp \left\{ -\frac{1}{2} \cdot \sum_{k=1}^n (x_k - \theta)^2 \right\} = \\ &= \frac{1}{\sqrt{2 \cdot \pi}^n} \cdot \exp \left\{ -\frac{1}{2} \cdot \sum_{k=1}^n (x_k^2 - \bar{x}^2) + n \cdot (\bar{x} - \theta)^2 \right\} = \\ &= \frac{1}{\sqrt{2 \cdot \pi}^n} \cdot \exp \left\{ -\frac{1}{2} \cdot \sum_{k=1}^n (x_k^2 - \bar{x}^2) \right\} \cdot \exp \left\{ n \cdot (\bar{x} - \theta)^2 \right\} \end{aligned}$$

Мы получили произведение двух функций: одна зависит лишь от статистики \bar{x} и параметра θ , а другая, зависит лишь от выборки (так

как выборочное среднее является функцией выборки)

$$\begin{cases} L(\vec{x}, \theta) = \frac{1}{\sqrt{2 \cdot \pi}^n} \cdot \exp \left\{ -\frac{1}{2} \cdot \sum_{k=1}^n (x_k^2 - \bar{x}^2) \right\} \cdot \exp \left\{ n \cdot (\bar{x} - \theta)^2 \right\} \\ h(\bar{x}, \theta) = \exp \left\{ n \cdot (\bar{x} - \theta)^2 \right\} \\ g(\vec{x}) = \frac{1}{\sqrt{2 \cdot \pi}^n} \cdot \exp \left\{ -\frac{1}{2} \cdot \sum_{k=1}^n (x_k^2 - \bar{x}^2) \right\} \end{cases}$$

$$\Rightarrow L(\vec{x}, \theta) = g(\vec{x}) \cdot h(\bar{x}, \theta)$$

Функция выборки допускает факторизацию со статистикой \bar{x} , а это значит, что выборочное среднее является достаточной статистикой.

Глава 3

Метод наименьших квадратов

Мы уже знаем, что нам не нужна вся выборка для построения хороших оценок — нам хватит достаточных статистик. Введя метод наименьших квадратов, мы избавимся от неприятной процедуры вычисления интегралов.

3.1 Гауссовские случайные вектора

3.1.1 Основные характеристики случайного вектора

Есть $\vec{\xi} = (\xi_1, \dots, \xi_n)$ — случайный вектор. С функцией распределения $F(\vec{\xi})$ возникают проблемы (скучновато и громоздко), поэтому будем использовать плотность распределения.

Определение 3.1.1: Плотность распределения случайного вектора

p — плотность распределения случайного вектора $\vec{\xi} = (\xi_1, \dots, \xi_n)$, если

1. Вероятность того, что вектор $\vec{\xi}$ окажется в множестве Δ , равна интегралу от плотности по этой области

$$\mathbb{P}\{\vec{\xi} \in \Delta\} = \int_{\Delta} p(\vec{u}) \, d\vec{u}$$

2. Во всех точках плотность неотрицательна

$$\forall \vec{x} \in \mathbb{R}^n : p(\vec{x}) \geq 0$$

3. Выполняется условие нормировки

$$\int_{\mathbb{R}^n} p(\vec{u}) d\vec{u} = 1$$

Естественным образом вводится определение характеристической функции.

Определение 3.1.2: Характеристическая функция случайного вектора

Значение характеристической функции случайного вектора $\vec{\xi}$ в точке $\vec{\lambda}$ считается по формуле

$$\varphi_{\vec{\xi}}(\vec{\lambda}) = M e^{i \cdot (\vec{\lambda}, \vec{\xi})} = M \exp \left\{ i \cdot \sum_{k=1}^n \lambda_k \cdot \xi_k \right\}$$

Когда существует плотность, имеем преобразование Фурье

$$\varphi_{\vec{\xi}}(\vec{\lambda}) = \int_{\mathbb{R}^n} p(\vec{u}) \cdot e^{i(\vec{\lambda}, \vec{u})} d\vec{u}$$

Определение 3.1.3: Математическое ожидание случайного вектора

Математическое ожидание случайного вектора $\vec{\xi} = (\xi_1, \dots, \xi_n)$ — вектор, элементы которого — математические ожидания компонент случайного вектора $\vec{\xi}$

$$M\vec{\xi} = (M\xi_1, \dots, M\xi_n)$$

Но что же является дисперсией случайного вектора?

3.1.2 Ковариационная матрица

Начнём с определения ковариации двух случайных величин.

Определение 3.1.4: Ковариация

Ковариация двух случайных величин ξ и η обозначается $\text{cov}(\xi, \eta)$ и считается по формуле

$$\text{cov}(\xi, \eta) = M [(\xi - M\xi) \cdot (\eta - M\eta)]$$

Замечание 3.1.5

Ковариация случайной величины ξ с ней же — её дисперсия

$$\text{cov}(\xi, \xi) = M[(\xi - M\xi) \cdot (\xi - M\xi)] = M[(\xi - M\xi)^2] = D\xi$$

Замечание 3.1.6

Ковариация симметрична

$$\text{cov}(\xi, \eta) = M[(\xi - M\xi) \cdot (\eta - M\eta)] = M[(\eta - M\eta) \cdot (\xi - M\xi)] = \text{cov}(\eta, \xi)$$

Определение 3.1.7

Ковариационная матрица двух случайных векторов $\vec{\xi} = (\xi_1, \dots, \xi_n)$ и $\vec{\eta} = (\eta_1, \dots, \eta_n)$ — матрица, в которой на пересечении i строки и j столбца стоит ковариация случайных величин ξ_i и η_j

$$\text{Cov}_{\vec{\xi}, \vec{\eta}} = \|\text{cov}(\xi_i, \eta_j)\|_{i,j=1}^n = \|M\{(\xi_i - M\xi_i) \cdot (\eta_j - M\eta_j)\}\|_{i,j=1}^n$$

$$\text{Cov}_{\vec{\xi}, \vec{\eta}} = \begin{bmatrix} \text{cov}(\xi_1, \eta_1) & \cdots & \text{cov}(\xi_1, \eta_n) \\ \vdots & \ddots & \vdots \\ \text{cov}(\xi_n, \eta_1) & \cdots & \text{cov}(\xi_n, \eta_n) \end{bmatrix}$$

Ковариационная матрица случайного вектора $\vec{\xi} = (\xi_1, \dots, \xi_n)$ имеет следующий вид

$$\text{Cov}_{\vec{\xi}, \vec{\xi}} = \|\text{cov}(\xi_i, \xi_j)\|_{i,j=1}^n = \|M\{(\xi_i - M\xi_i) \cdot (\xi_j - M\xi_j)\}\|_{i,j=1}^n$$

$$\text{Cov}_{\vec{\xi}, \vec{\xi}} = \begin{bmatrix} \text{cov}(\xi_1, \xi_1) & \cdots & \text{cov}(\xi_1, \xi_n) \\ \vdots & \ddots & \vdots \\ \text{cov}(\xi_n, \xi_1) & \cdots & \text{cov}(\xi_n, \xi_n) \end{bmatrix}$$

Замечание 3.1.8

На диагонали ковариационной матрицы $\text{Cov}_{\vec{\xi}, \vec{\xi}}$ случайного вектора ξ стоят дисперсии компонент вектора.

Случайный вектор находится во многомерном пространстве, а это значит, что имеется много направлений его размазывания, поэтому в качестве дисперсии нам нужна матрица.

Пример 3.1.9

Возьмём двумерный вектор с одним и тем же элементом в каждой координате — случайной величиной из стандартного нормального распределения

$$\vec{\xi} = (\xi, \xi), \quad \xi \sim N(0, 1)$$

Нетрудно посчитать, что ковариационная матрица будет заполнена единицами, так как во всех ячейках будет ковариация $\text{cov}(\xi, \xi)$, равная дисперсии случайной величины ξ , то есть, единице

$$\text{Cov}_{\vec{\xi}, \vec{\xi}} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

Пример 3.1.10

Возьмём опять же двумерный вектор, но с двумя независимыми случайными величинами из стандартного нормального распределения

$$\vec{\xi} = (\xi_1, \xi_2), \quad \xi_1, \xi_2 \sim N(0, 1)$$

На диагонали будут стоять единицы — дисперсии случайных величин. Если две случайные величины независимы, то их ковариация равна нулю [7, с. 244]. Это в свою очередь означает, что вне диагонали будут нули

$$\text{Cov}_{\vec{\xi}, \vec{\xi}} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

3.1.3 Свойства ковариационной матрицы

Литература

- [1] Боровков А. А. Математическая статистика. Санкт-Петербург: Лань, 2010. 705 с.
- [2] Боровков А. А. Теория Вероятностей. Москва: Эдиториал УРСС, 1999. 472 с.
- [3] Дороговцев А. Я. Элементы общей теории меры и интеграла. Киев: Выща школа. Головное издательство, 1989. 152 с.
- [4] Ширяев А. Н. Вероятность-1. Москва: МЦНМО, 2004. 520 с.
- [5] А. Н. Колмогоров С. В. Фомин. Элементы теории функций и функционального анализа. Москва: Наука, 1976. 543 с.
- [6] В.Б. Горяинов И.В. Павлов Г.М. Цветкова и др. Математическая статистика. Москва: МГТУ им. Н. Э. Баумана, 2001. 424 с.
- [7] Феллер В. Введение в теорию вероятностей и её приложения. Том 1. Москва: Мир, 1984. 528 с.

Предметный указатель

- Сигма-алгебра, порождённая случайной величиной, 29
- функция
 - правдоподобия, 15
 - факторизация, 63
 - вариационного ряда, 28
- функция распределения
 - эмпирическая, 3
 - неизвестная, 3
 - выборочная, 3
- гистограмма, 5
- характеристическая функция
 - случайного вектора, 68
- количество информации Фишера, 17
- ковариационная матрица, 69
- ковариация, 68
- математическое ожидание
 - случайного вектора, 68
- множество уровня, 30
- неизвестный параметр, 8
- неравенство
 - Рао-Крамера, 18
- оценка, 9
 - эффективная, 20
 - максимального правдоподобия, 23
 - несмещённая, 10
 - сильно состоятельная, 10
 - состоятельная, 10
 - улучшенная, 61
- плотность распределения
 - случайного вектора, 67
- проекция
 - случайной величины, 37
- распределение
 - экспоненциальное, 22
- сигма-алгебра
 - порождённая случайной величиной, 28
- симметризация, 25
- случайная величина
 - измеримая относительно сигма-алгебры, 31
- случайный вектор
 - характеристическая функция, 68
 - математическое ожидание, 68
 - плотность распределения, 67
- статистика, 9
 - достаточная, 60
- теорема
 - Колмогорова, 13
- уравнение
 - правдоподобия, 24
- условное
 - математическое ожидание, 35
 - гладких функций, 54
 - относительно конечной сигма-алгебры, 39
 - свойства, 49
 - в общем виде, 42
 - случайных величин с совместной плотностью, 47
 - распределение, 58
- вариационный ряд, 24
- выборочная дисперсия, 13
- выборочное среднее, 12
- вклад выборки, 16

Оглавление

| | | |
|----------|--|-----------|
| 1 | Основы | 3 |
| 1.1 | Методы оценок характеристик наблюдаемых случайных величин | 3 |
| 1.1.1 | Эмпирическая функция распределения | 3 |
| 1.1.2 | Гистограмма | 4 |
| 1.1.3 | Оценка неизвестных параметров | 8 |
| 1.1.4 | Выборочные оценки. Метод моментов | 11 |
| 1.2 | Свойства оценок | 13 |
| 1.2.1 | Неравенство Рао-Крамера | 13 |
| 1.2.2 | Метод максимального правдоподобия | 20 |
| 2 | Достаточные статистики | 25 |
| 2.1 | Оптимальная оценка | 25 |
| 2.2 | σ -алгебра, порождённая случайной величиной | 28 |
| 2.3 | Случайная величина, измеримая относительно σ -алгебры | 31 |
| 2.4 | Условное математическое ожидание | 35 |
| 2.4.1 | Проекция вектора | 35 |
| 2.4.2 | Проекция случайной величины | 36 |
| 2.4.3 | Условное математическое ожидание | 41 |
| 2.4.4 | Свойства условного математического ожидания | 49 |
| 2.4.5 | Условное математическое ожидание функции произвольной случайной величины | 50 |
| 2.4.6 | Пример | 54 |
| 2.5 | Условные распределения | 58 |
| 2.6 | Достаточные статистики | 60 |
| 3 | Метод наименьших квадратов | 67 |
| 3.1 | Гауссовские случайные вектора | 67 |
| 3.1.1 | Основные характеристики случайного вектора | 67 |
| 3.1.2 | Ковариационная матрица | 68 |
| 3.1.3 | Свойства ковариационной матрицы | 70 |